

## **BAB 4**

### **HASIL PENELITIAN**

#### **4.1 *Testing Environment***

##### **4.1.1 Spesifikasi Sistem**

###### **4.1.1.1 Device**

Penelitian yang diimplementasikan ke dalam sebuah web aplikasi dibangun dan dijalankan pada perangkat pc dengan spesifikasi sebagai berikut.

Operating System	:	Windows 10 Pro Edition
CPU	:	Intel Core i7-4710HQ CPU @2.50 GHz
RAM	:	8.00 GB
Internal Memory	:	1 TB

###### **4.1.1.2 Server**

Sistem web aplikasi ini dijalankan dengan Apache HTTP Server 2.4.

##### **4.1.2 Perangkat Lunak**

Berikut adalah perangkat lunak yang digunakan dalam penelitian ini

1. Eclipse Neon 4.6 IDE
2. Notepad++ 7.3.3
3. Microsoft Excel 2010
4. XAMPP 3.2.2
5. Apache HTTP Server 2.4

##### **4.1.3 *Library***

Berikut adalah *library* yang digunakan dalam pembangunan sistem prediksi.

1. Scikit-learn 0.18.1
2. LIWC2015
3. SPLICE 0.9.0

4. Numpy 1.13.0
5. Pandas 0.20.0
6. Keras 2.0.4
7. Theano 0.9.0
8. Imbalanced-learn 0.2.1
9. NLTK 3.2.4

## 4.2 Hasil

### 4.2.1 Distribusi Data

Distribusi data dari *dataset myPersonality* dapat dilihat pada Tabel 4.1 dengan total sebanyak 250 data *user* Facebook.

**Tabel 4.1** Distribusi data *myPersonality*

Value	<i>Openness</i>	<i>Conscientiousness</i>	<i>Extraversion</i>	<i>Agreeableness</i>	<i>Neuroticism</i>
Yes	176	130	96	134	99
No	74	120	154	116	151

Distribusi data dari *dataset Manual Gathering* dapat dilihat pada Tabel 4.2 dengan total sebanyak 150 data *user* Facebook yang didapatkan secara manual.

**Tabel 4.2** Distribusi data *Manual Gathering*

Value	<i>Openness</i>	<i>Conscientiousness</i>	<i>Extraversion</i>	<i>Agreeableness</i>	<i>Neuroticism</i>
Yes	97	63	38	81	50
No	53	87	112	69	100

Distribusi data dari gabungan kedua *dataset* di atas dapat dilihat pada Tabel 4.3 dengan total sebanyak 400 data *user*.

**Tabel 4.3** Distribusi data gabungan *myPersonality* dan Manual Data Gathering

Value	<i>Openness</i>	<i>Conscientiousness</i>	<i>Extraversion</i>	<i>Agreeableness</i>	<i>Neuroticism</i>
Yes	273	193	134	215	149
No	127	207	266	185	251

#### 4.2.2 Faktor Skenario Percobaan

Beberapa faktor skenario percobaan yang akan digunakan selama proses *testing* untuk mendapatkan hasil terbaik dari implementasi *machine learning* ini terbagi dua yaitu:

##### 4.2.2.1 *Features Selection*

Feature utama yang digunakan dari penelitian ini yaitu LIWC sebanyak 85 *features*, SPLICE sebanyak 94 *features*, dan SNA *features* sebanyak 7 *features* akan melewati proses *feature selections* atau pemilihan fitur selama proses *testing* berjalan untuk mendapatkan feature yang paling optimal dalam menghasilkan tingkat akurasi paling tinggi.

Modul *Features Selection* ini berjalan secara otomatis dan dinamis selama proses berjalan dan feature paling optimal akan muncul di akhir bersamaan dengan tingkat akurasinya. *Features selection* hanya akan digunakan untuk skenario implementasi *machine learning*.

##### 4.2.2.2 *Resampling*

*Resampling* adalah proses dimana *dataset* yang ada dilakukan manipulasi data dan duplikasi data untuk membuat sebuah data memiliki elemen yang seimbang. Proses *resampling* terbagi menjadi 2 yaitu:

###### – *Oversampling*

Menambahkan data ke data dengan persentase minoritas. Tujuan *Oversampling* pada penelitian ini karena ada *dataset* dimana elemennya tidak seimbang. Sebagai contoh terdapat 70% pria dan 30% wanita. Hasil dari *testing* biasanya akan buruk dikarenakan faktor tersebut. Untuk itu, *oversampling* akan menambahkan elemen yang menjadi minoritas agar data menjadi seimbang.

– *Undersampling*

Proses *undersampling* hanya berbanding terbalik dengan *Oversampling*. Jika *Oversampling* menambahkan data, *Undersampling* mengurangi data yang memiliki persentase mayoritas untuk menyeimbangkan data.

Faktor skenario *resampling* ini akan digunakan pada skenario implementasi *machine learning* dan juga skenario implementasi *deep learning*.

### 4.2.3 Implementasi *Machine learning*

#### 4.2.3.1 Skenario

Implementasi *machine learning* dalam *testing* ini akan menggunakan 5 jenis algoritma (Support Vector Machine, Naïve Bayes, Logistic Regression, Gradient Boosting, dan LDA) dan 3 *features* utama (LIWC, SPLICE, dan SNA). Kemudian, *dataset* yang digunakan terbagi menjadi 3 seperti dijelaskan pada Bagian 4.2.1 mengenai distribusi data.

Dari faktor skenario diatas pada Bagian 4.2.2, *machine learning* akan menggunakan kedua faktor tersebut yaitu *Features Selection* (Bagian 4.2.2.1) dan *Resampling* (Bagian 4.2.2.2) sehingga dapat dibentuk skenario percobaan untuk *Machine learning* sebagai berikut:

1. Penggunaan *dataset myPersonality*, percobaan tanpa menggunakan *Features Selection* dan tanpa menggunakan *Resampling*.
2. Penggunaan *dataset myPersonality*, percobaan dengan menggunakan *Features Selection*.
3. Penggunaan *dataset myPersonality*, percobaan dengan menggunakan *Undersampling*.
4. Penggunaan *dataset myPersonality*, percobaan dengan menggunakan *Oversampling*.

5. Penggunaan *dataset myPersonality*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Undersampling*.
6. Penggunaan *dataset myPersonality*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Oversampling*.
7. Penggunaan *dataset Manual Gathering*, percobaan tanpa menggunakan *Features Selection* dan tanpa menggunakan *Resampling*.
8. Penggunaan *dataset Manual Gathering*, percobaan dengan menggunakan *Features Selection*.
9. Penggunaan *dataset Manual Gathering*, percobaan dengan menggunakan *Undersampling*.
10. Penggunaan *dataset Manual Gathering*, percobaan dengan menggunakan *Oversampling*.
11. Penggunaan *dataset Manual Gathering*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Undersampling*.
12. Penggunaan *dataset Manual Gathering*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Oversampling*.
13. Penggunaan *dataset gabungan*, percobaan tanpa menggunakan *Features Selection* dan tanpa menggunakan *Resampling*.
14. Penggunaan *dataset gabungan*, percobaan dengan menggunakan *Features Selection*.
15. Penggunaan *dataset gabungan*, percobaan dengan menggunakan *Undersampling*.
16. Penggunaan *dataset gabungan*, percobaan dengan menggunakan *Oversampling*.
17. Penggunaan *dataset gabungan*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Undersampling*.
18. Penggunaan *dataset gabungan*, percobaan dengan menggunakan *Features Selection* dan dengan menggunakan *Oversampling*.

Keterangan pada tabel percobaan:

	= Header Tabel percobaan yang menggunakan <i>dataset myPersonality</i>
	= Header Tabel percobaan yang menggunakan <i>dataset Manual Gathering</i>
	= Header Tabel percobaan yang menggunakan <i>dataset gabungan</i>

O = *Traits Openness*

C = *Traits Conscientiousness*

E = *Traits Extraversion*

A = *Traits Agreeableness*

N = *Traits Neuroticism*

**Bold** = Akurasi tertinggi pada masing-masing *Features*

**Highlight** = Akurasi tertinggi pada sebuah *Traits*

#### 4.2.3.2 Dataset *myPersonality*

Percobaan dengan skenario 1-6 dilakukan dengan menggunakan *dataset myPersonality* (Kosinski, 2015). Untuk kemudian dibandingkan dengan penggunaan *dataset* yang didapatkan secara manual dan gabungan keduanya.

##### 4.2.3.2.1 Skenario 1 (Percobaan tanpa menggunakan *Features* *Selection* dan tanpa *Resampling*)

<i>Features</i>	Algorithm	O	C	E	A	N
LIWC	NAÏVE BAYES	64.80%	50.00%	51.60%	<b>54.80%</b>	54.40%
	SVM	70.00%	50.00%	60.00%	46.80%	58.00%
	Logistic Regression	<b>70.40%</b>	50.00%	61.60%	51.20%	60.40%
	GRADIENT BOOSTING	63.20%	53.20%	57.60%	53.60%	56.80%
	LDA	62.00%	<b>54.00%</b>	<b>64.40%</b>	53.60%	<b>60.80%</b>
SPLICE	NAÏVE BAYES	59.20%	<b>52.00%</b>	53.60%	53.60%	47.20%
	SVM	62.00%	51.60%	53.20%	54.00%	50.40%
	Logistic Regression	63.60%	51.60%	<b>58.00%</b>	51.60%	54.40%
	GRADIENT BOOSTING	62.00%	50.00%	54.40%	50.80%	54.00%

	LDA	<b>64.00%</b>	51.60%	54.00%	<b>58.00%</b>	<b>55.20%</b>
SNA	NAÏVE BAYES	58.00%	54.80%	<b>68.80%</b>	45.60%	52.40%
	SVM	58.80%	53.60%	51.60%	42.00%	38.80%
	Logistic Regression	<b>70.00%</b>	54.00%	68.40%	52.00%	<b>58.40%</b>
	GRADIENT BOOSTING	63.20%	48.80%	68.00%	<b>55.20%</b>	54.00%
	LDA	69.20%	<b>56.40%</b>	66.00%	54.80%	57.60%
LIWC + SPLICE	NAÏVE BAYES	64.80%	50.80%	53.60%	<b>54.00%</b>	46.80%
	SVM	59.60%	50.80%	54.00%	51.20%	50.80%
	Logistic Regression	63.60%	52.40%	56.80%	51.20%	54.00%
	GRADIENT BOOSTING	<b>65.60%</b>	<b>54.40%</b>	54.80%	47.60%	<b>60.00%</b>
	LDA	58.00%	54.00%	<b>63.20%</b>	49.60%	50.00%
LIWC + SNA	NAÏVE BAYES	58.00%	<b>55.20%</b>	<b>68.80%</b>	45.60%	52.40%
	SVM	58.80%	53.60%	51.60%	41.20%	38.80%
	Logistic Regression	<b>70.00%</b>	54.00%	68.40%	51.20%	59.20%
	GRADIENT BOOSTING	64.80%	50.40%	60.00%	<b>55.20%</b>	<b>60.40%</b>
	LDA	62.40%	53.60%	66.40%	52.80%	59.60%
SPLICE + SNA	NAÏVE BAYES	40.00%	49.60%	<b>64.00%</b>	51.20%	44.00%
	SVM	62.80%	50.80%	63.20%	<b>54.00%</b>	47.20%
	Logistic Regression	<b>68.40%</b>	<b>54.80%</b>	63.60%	45.20%	<b>59.20%</b>
	GRADIENT BOOSTING	64.80%	50.00%	62.40%	48.40%	55.60%
	LDA	60.80%	53.20%	56.40%	53.20%	56.40%
LIWC + SPLICE + SNA	NAÏVE BAYES	40.00%	49.60%	64.00%	51.20%	44.00%
	SVM	62.80%	50.80%	63.20%	54.00%	47.20%
	Logistic Regression	<b>68.40%</b>	<b>56.40%</b>	<b>65.60%</b>	46.80%	57.60%
	GRADIENT BOOSTING	63.60%	53.60%	60.80%	<b>52.80%</b>	<b>60.00%</b>
	LDA	60.40%	54.40%	63.20%	47.60%	52.40%

**Tabel 4.4** Hasil Percobaan Skenario 1 tanpa *Features Selection* dan tanpa *Resampling*

Dari Tabel 4.4 diatas, dapat dilihat bahwa nilai akurasi tertinggi untuk *traits Openness* adalah algoritma Logistic Regression dengan akurasi 70.4% menggunakan fitur LIWC, *traits Conscientiousness* dapat menghasilkan akurasi paling tinggi dengan 56.4% algoritma Logistic Regression dan fitur gabungan LIWC+SPLICE+ SNA atau

algoritma LDA dengan fitur SNA. Akurasi paling tinggi untuk *traits Extraversion* adalah 68.8% dengan algoritma Naïve Bayes untuk fitur SNA dan fitur LIWC+SNA. Akurasi paling tinggi untuk *traits Agreeableness* menggunakan algoritma LDA dan fitur SPLICE dengan akurasi 58%. Algoritma LDA kembali menjadi akurasi tertinggi untuk *traits Neuroticism* dengan akurasi 60.8%. Dalam skenario 1 ini yang tidak menggunakan fitur *features selection* ataupun proses *resampling*, algoritma paling dominan adalah algoritma LDA dengan beragam fitur.

#### 4.2.3.2.2 Skenario 2 (Percobaan dengan menggunakan *Features Selection*)

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	70.00%	48.80%	59.60%	47.60%	51.20%
	SVM	<b>70.40%</b>	<b>56.00%</b>	61.60%	52.40%	<b>60.40%</b>
	Logistic Regression	<b>70.40%</b>	53.60%	61.60%	53.60%	<b>60.40%</b>
	GRADIENT BOOSTING	62.00%	54.40%	60.80%	<b>56.40%</b>	58.80%
	LDA	69.60%	52.80%	<b>62.80%</b>	53.60%	<b>60.40%</b>
SPLICE	NAÏVE BAYES	59.20%	51.60%	53.60%	<b>54.00%</b>	49.60%
	SVM	44.00%	48.40%	51.60%	51.20%	54.80%
	Logistic Regression	<b>65.60%</b>	52.00%	<b>56.40%</b>	52.00%	<b>57.60%</b>
	GRADIENT BOOSTING	63.60%	50.80%	54.40%	51.20%	53.60%
	LDA	62.40%	<b>54.00%</b>	53.60%	<b>54.00%</b>	<b>57.60%</b>
SNA	NAÏVE BAYES	58.00%	<b>54.80%</b>	<b>68.80%</b>	45.60%	52.40%
	SVM	58.80%	53.60%	51.60%	41.60%	38.80%
	Logistic Regression	<b>70.00%</b>	53.60%	68.40%	50.80%	57.60%
	GRADIENT BOOSTING	61.20%	48.40%	68.00%	50.40%	<b>59.20%</b>
	LDA	<b>70.00%</b>	52.40%	68.00%	<b>56.80%</b>	58.40%
LIWC + SPLICE	NAÏVE BAYES	60.80%	52.00%	52.80%	<b>53.60%</b>	48.80%
	SVM	45.20%	51.60%	54.00%	50.40%	54.00%
	Logistic Regression	<b>65.20%</b>	52.00%	56.40%	51.60%	<b>56.80%</b>
	GRADIENT BOOSTING	63.20%	52.00%	<b>58.00%</b>	50.80%	53.60%



	LDA	62.00%	<b>55.20%</b>	55.60%	52.80%	56.40%
LIWC + SNA	NAÏVE BAYES	58.00%	<b>54.80%</b>	<b>68.80%</b>	45.60%	52.40%
	SVM	58.80%	53.60%	51.60%	41.60%	38.80%
	Logistic Regression	<b>70.00%</b>	54.00%	68.40%	52.00%	58.00%
	GRADIENT BOOSTING	62.40%	56.00%	66.80%	<b>60.40%</b>	<b>57.20%</b>
	LDA	68.80%	51.60%	68.40%	54.80%	56.40%
SPLICE + SNA	NAÏVE BAYES	40.40%	50.00%	64.80%	52.00%	44.40%
	SVM	62.80%	50.80%	63.20%	<b>56.80%</b>	46.40%
	Logistic Regression	<b>66.40%</b>	<b>54.80%</b>	<b>65.20%</b>	44.80%	58.00%
	GRADIENT BOOSTING	65.20%	50.80%	61.60%	52.80%	54.00%
	LDA	64.00%	52.80%	60.40%	54.00%	<b>59.20%</b>
LIWC + SPLICE + SNA	NAÏVE BAYES	40.40%	50.00%	<b>64.80%</b>	52.00%	44.00%
	SVM	62.80%	50.80%	63.20%	<b>56.80%</b>	47.20%
	Logistic Regression	<b>68.80%</b>	54.80%	63.60%	46.00%	57.60%
	GRADIENT BOOSTING	61.60%	50.00%	60.40%	50.00%	<b>60.00%</b>
	LDA	61.60%	<b>56.40%</b>	60.00%	53.60%	52.40%

**Tabel 4.5** Hasil Percobaan Skenario 2 dengan *Features Selection*

Dari Tabel 4.5 diatas, dapat dilihat bahwa di skenario 2 ini nilai akurasi tertinggi untuk *traits Openness* masih sama dengan algoritma Logistic Regression dan SVM dengan akurasi 70.4% menggunakan fitur LIWC, *traits Conscientiousness* juga menghasilkan akurasi 56.4% dengan algoritma LDA dan fitur gabungan LIWC+SPLICE+ SNA. Akurasi paling tinggi untuk *traits Extraversion* persis sama dengan skenario 1 setinggi 68.8% dengan algoritma Naïve Bayes untuk fitur SNA dan fitur LIWC+SNA. Akurasi paling tinggi untuk *traits Agreeableness* sedikit meningkat dengan menggunakan Gradient Boosting dengan akurasi 60.4%. Untuk *traits Neuroticism*, akurasi paling tinggi adalah 60.4% yang diperoleh dengan dominan oleh fitur LIWC. Dalam skenario 2 ini penggunaan *Features Selection* tidak terlalu berpengaruh pada hasil akurasi karena dapat dilihat beberapa akurasi masih mempunyai nilai yang sama dengan skenario 1.

**4.2.3.2.3 Skenario 3 (Percobaan dengan menggunakan  
Undersampling)**

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	35.60%	50.00%	46.80%	<b>55.60%</b>	49.20%
	SVM	44.00%	51.60%	53.60%	46.80%	48.40%
	Logistic Regression	43.20%	<b>54.40%</b>	49.60%	48.40%	52.40%
	GRADIENT BOOSTING	44.00%	51.60%	55.60%	52.80%	53.60%
	LDA	<b>49.60%</b>	54.00%	<b>56.00%</b>	52.40%	<b>58.00%</b>
SPLICE	NAÏVE BAYES	37.60%	50.00%	42.40%	<b>54.00%</b>	43.60%
	SVM	39.60%	51.60%	48.00%	50.40%	50.80%
	Logistic Regression	45.20%	50.80%	<b>51.60%</b>	50.80%	50.40%
	GRADIENT BOOSTING	43.20%	49.20%	44.80%	49.60%	<b>54.00%</b>
	LDA	<b>53.60%</b>	<b>52.40%</b>	<b>51.60%</b>	52.80%	52.80%
SNA	NAÏVE BAYES	38.00%	57.60%	<b>68.00%</b>	48.00%	50.80%
	SVM	<b>46.40%</b>	51.20%	54.80%	40.00%	42.00%
	Logistic Regression	41.20%	52.00%	66.40%	52.80%	58.00%
	GRADIENT BOOSTING	41.60%	53.20%	55.20%	<b>56.40%</b>	53.60%
	LDA	<b>46.40%</b>	<b>58.40%</b>	56.40%	53.60%	<b>60.00%</b>
LIWC + SPLICE	NAÏVE BAYES	41.20%	50.40%	45.60%	<b>55.60%</b>	45.60%
	SVM	44.00%	53.60%	46.00%	41.60%	<b>54.40%</b>
	Logistic Regression	45.20%	51.60%	49.60%	49.60%	50.00%
	GRADIENT BOOSTING	46.80%	<b>55.20%</b>	48.80%	50.00%	51.60%
	LDA	<b>52.00%</b>	52.40%	<b>57.60%</b>	50.40%	54.00%
LIWC + SNA	NAÏVE BAYES	38.00%	<b>57.60%</b>	<b>68.00%</b>	48.00%	50.80%
	SVM	47.20%	57.20%	61.20%	42.40%	45.60%
	Logistic Regression	42.00%	52.00%	66.40%	52.80%	<b>58.40%</b>
	GRADIENT BOOSTING	48.40%	50.80%	51.20%	50.40%	57.60%
	LDA	<b>48.80%</b>	54.80%	56.80%	<b>54.00%</b>	50.80%
SPLICE + SNA	NAÏVE BAYES	40.80%	51.60%	52.80%	52.40%	42.00%
	SVM	44.80%	54.00%	52.00%	50.40%	52.00%
	Logistic Regression	48.40%	<b>55.20%</b>	<b>60.00%</b>	50.80%	56.40%

LIWC + SPLICE + SNA	GRADIENT BOOSTING	47.60%	51.20%	55.60%	53.20%	<b>56.80%</b>
	LDA	<b>53.20%</b>	54.80%	50.80%	<b>54.80%</b>	53.60%
	NAÏVE BAYES	42.40%	51.60%	52.80%	52.40%	42.00%
	SVM	44.40%	49.60%	54.80%	51.60%	50.00%
	Logistic Regression	45.20%	51.60%	<b>58.80%</b>	<b>55.60%</b>	54.00%
	GRADIENT BOOSTING	50.00%	49.60%	55.60%	49.60%	<b>56.80%</b>
	LDA	<b>54.40%</b>	<b>54.80%</b>	54.00%	48.80%	46.80%

**Tabel 4.6** Hasil Percobaan Skenario 3 dengan *Undersampling*

Hasil pada skenario 3 yang tidak menggunakan *Features Selection* dan hanya menggunakan *Undersampling* ternyata membuat akurasi secara rata-rata mengalami penurunan dari skenario sebelumnya. Akurasi tertinggi yang diperoleh Openess hanya 54.4%. Untuk *traits Conscientiousness* akurasi tertinggi hanya mengalami sedikit peningkatan dengan 58.8%. *Traits Extraversion* dengan 68% dan *traits Agreeableness* 55.6% serta *traits Neuroticism* dengan 60%. Skenario 3 masih memiliki akurasi tertinggi yang sejajar nilainya dengan skenario sebelumnya. Tetapi, jika dilihat secara keseluruhan memiliki penurunan nilai akurasi jika dibandingkan dengan dua skenario yang telah dilakukan sebelumnya.

#### 4.2.3.2.4 Skenario 4 (Percobaan dengan menggunakan *Oversampling*)

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	48.80%	49.20%	50.00%	52.00%	50.80%
	SVM	54.80%	50.40%	52.80%	49.20%	53.20%
	Logistic Regression	56.00%	53.20%	50.80%	48.40%	53.60%
	GRADIENT BOOSTING	<b>57.20%</b>	<b>56.00%</b>	57.20%	51.60%	57.60%
	LDA	55.20%	54.80%	<b>60.00%</b>	<b>53.20%</b>	<b>58.80%</b>
SPLICE	NAÏVE BAYES	41.20%	<b>52.00%</b>	52.00%	<b>56.40%</b>	43.20%
	SVM	49.60%	49.60%	49.60%	48.40%	54.00%

	Logistic Regression	54.00%	51.20%	<b>54.80%</b>	51.60%	48.80%
	GRADIENT BOOSTING	<b>60.80%</b>	50.40%	51.60%	54.40%	<b>56.80%</b>
	LDA	57.60%	<b>52.00%</b>	52.00%	<b>56.40%</b>	55.60%
SNA	NAÏVE BAYES	37.20%	<b>59.20%</b>	<b>65.60%</b>	44.00%	49.60%
	SVM	50.40%	55.20%	47.20%	45.20%	38.40%
	Logistic Regression	45.20%	54.40%	61.20%	49.20%	<b>58.00%</b>
	GRADIENT BOOSTING	<b>57.20%</b>	48.80%	64.80%	<b>52.80%</b>	55.20%
	LDA	52.40%	58.40%	59.60%	52.00%	57.20%
LIWC + SPLICE	NAÏVE BAYES	46.40%	50.80%	51.20%	<b>56.40%</b>	41.60%
	SVM	50.00%	52.00%	52.40%	46.00%	51.60%
	Logistic Regression	54.80%	50.00%	57.20%	51.20%	49.60%
	GRADIENT BOOSTING	<b>62.80%</b>	51.20%	54.00%	51.60%	<b>59.20%</b>
	LDA	54.40%	<b>54.40%</b>	<b>61.20%</b>	49.60%	48.80%
LIWC + SNA	NAÏVE BAYES	37.20%	<b>59.20%</b>	<b>65.60%</b>	44.40%	49.60%
	SVM	48.40%	55.20%	46.80%	45.20%	38.40%
	Logistic Regression	46.40%	54.40%	61.20%	48.80%	<b>58.40%</b>
	GRADIENT BOOSTING	56.40%	54.80%	57.20%	53.20%	57.20%
	LDA	<b>56.80%</b>	54.40%	62.80%	<b>53.60%</b>	55.20%
SPLICE + SNA	NAÏVE BAYES	41.20%	50.40%	60.00%	49.20%	43.20%
	SVM	50.80%	51.20%	52.40%	48.40%	52.00%
	Logistic Regression	54.00%	53.60%	59.60%	49.20%	<b>57.20%</b>
	GRADIENT BOOSTING	<b>56.80%</b>	46.80%	<b>60.80%</b>	51.60%	55.60%
	LDA	<b>56.80%</b>	<b>55.60%</b>	53.20%	<b>54.00%</b>	52.00%
LIWC + SPLICE + SNA	NAÏVE BAYES	41.20%	50.40%	60.00%	49.20%	43.20%
	SVM	50.80%	51.20%	52.40%	48.40%	52.00%
	Logistic Regression	55.60%	53.60%	61.60%	48.80%	59.20%
	GRADIENT BOOSTING	<b>61.20%</b>	53.20%	58.00%	<b>53.60%</b>	<b>60.40%</b>
	LDA	56.40%	<b>55.60%</b>	<b>64.40%</b>	50.40%	50.40%

**Tabel 4.7** Hasil Percobaan Skenario 4 dengan *Oversampling*

Skenario 4 kali ini pada Tabel 4.7 diatas menunjukkan bahwa proses *Resampling* (*Undersampling* dan *Resampling*) yang diterapkan ternyata tidak meningkatkan hasil akurasi. Karena secara

keseluruhan dapat dilihat bahwa akurasi menurun secara signifikan, walaupun akurasi tertinggi masih cukup mendekati dengan akurasi tertinggi skenario tanpa proses *Resampling*.

#### 4.2.3.2.5 Skenario 5 (Percobaan dengan menggunakan *Features Selection* dan dengan *Undersampling*)

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	48.00%	48.80%	57.20%	46.80%	36.80%
	SVM	55.20%	52.40%	54.00%	53.60%	<b>54.40%</b>
	Logistic Regression	<b>56.40%</b>	50.80%	54.80%	53.20%	52.00%
	GRADIENT BOOSTING	42.40%	<b>53.20%</b>	46.00%	<b>63.20%</b>	46.80%
	LDA	50.40%	<b>53.20%</b>	<b>59.20%</b>	52.80%	50.00%
SPLICE	NAÏVE BAYES	40.00%	50.80%	42.00%	54.00%	45.60%
	SVM	50.00%	<b>55.20%</b>	<b>52.40%</b>	<b>56.80%</b>	41.60%
	Logistic Regression	45.20%	53.60%	50.80%	51.20%	48.80%
	GRADIENT BOOSTING	46.80%	51.20%	47.60%	52.80%	54.00%
	LDA	<b>51.20%</b>	51.60%	51.60%	52.00%	<b>54.40%</b>
SNA	NAÏVE BAYES	38.00%	<b>57.60%</b>	<b>67.60%</b>	48.00%	50.80%
	SVM	<b>44.40%</b>	53.60%	57.60%	43.60%	46.00%
	Logistic Regression	41.60%	52.00%	66.00%	52.80%	<b>58.80%</b>
	GRADIENT BOOSTING	43.60%	50.80%	62.80%	<b>55.20%</b>	52.80%
	LDA	43.60%	54.40%	58.40%	54.80%	56.80%
LIWC + SPLICE	NAÏVE BAYES	40.00%	50.40%	42.00%	54.00%	46.40%
	SVM	46.80%	52.40%	52.80%	<b>54.80%</b>	45.20%
	Logistic Regression	44.80%	<b>52.80%</b>	50.00%	52.00%	48.80%
	GRADIENT BOOSTING	45.20%	48.80%	46.00%	54.00%	<b>54.80%</b>
	LDA	<b>53.20%</b>	<b>52.80%</b>	<b>55.20%</b>	52.80%	51.20%
LIWC + SNA	NAÏVE BAYES	38.00%	<b>57.60%</b>	<b>68.00%</b>	48.00%	50.80%
	SVM	<b>47.20%</b>	49.60%	51.60%	43.20%	45.60%
	Logistic Regression	42.80%	52.00%	66.00%	52.80%	<b>58.00%</b>
	GRADIENT BOOSTING	<b>47.20%</b>	55.60%	59.20%	<b>56.80%</b>	55.20%
	LDA	46.00%	54.40%	63.60%	54.80%	55.60%

SPLICE + SNA	NAÏVE BAYES	41.60%	51.60%	53.20%	52.80%	42.40%
	SVM	44.40%	51.60%	58.80%	52.00%	50.80%
	Logistic Regression	44.00%	<b>54.80%</b>	<b>61.60%</b>	52.80%	<b>57.20%</b>
	GRADIENT BOOSTING	<b>48.40%</b>	50.40%	56.00%	<b>54.40%</b>	56.80%
	LDA	48.00%	52.00%	53.20%	53.60%	55.60%
LIWC + SPLICE + SNA	NAÏVE BAYES	41.60%	51.60%	53.20%	52.80%	42.00%
	SVM	44.40%	52.00%	56.80%	49.20%	50.00%
	Logistic Regression	49.20%	54.80%	<b>61.20%</b>	51.60%	54.00%
	GRADIENT BOOSTING	<b>52.00%</b>	50.80%	53.60%	53.20%	<b>56.80%</b>
	LDA	49.20%	<b>55.60%</b>	55.20%	<b>54.80%</b>	46.80%

**Tabel 4.8** Hasil Percobaan Skenario 5 dengan *Features Selection* dan *Undersampling*

Percobaan di skenario 5 ini adalah menggabungkan *Features Selection* dan *Undersampling*. Pada Tabel 4.8 diatas ternyata hasil menunjukkan bahwa tidak ada peningkatan akurasi secara signifikan dengan menggunakan dua faktor skenario tersebut, karena tidak ada akurasi tertinggi yang lebih tinggi daripada hasil akurasi tertinggi di skenario sebelumnya kecuali *traits Agreeableness* dengan akurasi 63.2% yang lebih tinggi 2.8% daripada akurasi tertinggi sebelumnya pada skenario 2.

#### 4.2.3.2.6 Skenario 6 (Percobaan dengan menggunakan *Features Selection* dan dengan *Oversampling*)

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	54.40%	48.40%	56.00%	47.20%	37.60%
	SVM	55.20%	52.80%	54.80%	52.80%	51.60%
	Logistic Regression	54.80%	50.00%	54.00%	53.60%	50.80%
	GRADIENT BOOSTING	<b>59.20%</b>	<b>56.40%</b>	51.20%	<b>59.60%</b>	<b>53.20%</b>
	LDA	51.20%	54.80%	<b>59.20%</b>	55.20%	50.40%
SPLICE	NAÏVE BAYES	41.20%	51.20%	50.80%	<b>56.00%</b>	44.00%
	SVM	44.40%	50.40%	54.40%	52.40%	48.40%

	Logistic Regression	51.60%	53.20%	<b>55.20%</b>	52.00%	50.80%
	GRADIENT BOOSTING	<b>60.40%</b>	<b>54.00%</b>	54.00%	52.40%	55.20%
	LDA	58.80%	53.60%	54.00%	51.20%	<b>57.20%</b>
SNA	NAÏVE BAYES	37.20%	<b>59.20%</b>	65.60%	44.00%	49.60%
	SVM	50.40%	55.20%	49.60%	45.20%	38.40%
	Logistic Regression	45.20%	54.40%	61.20%	48.80%	58.00%
	GRADIENT BOOSTING	<b>55.20%</b>	50.00%	<b>66.80%</b>	<b>52.00%</b>	56.40%
	LDA	45.60%	54.00%	61.20%	51.20%	<b>58.80%</b>
LIWC + SPLICE	NAÏVE BAYES	41.60%	52.00%	53.20%	<b>56.00%</b>	43.60%
	SVM	53.60%	54.00%	54.40%	48.80%	44.80%
	Logistic Regression	52.40%	52.80%	55.20%	51.20%	50.80%
	GRADIENT BOOSTING	<b>58.80%</b>	50.80%	54.00%	54.00%	<b>53.20%</b>
	LDA	53.60%	<b>56.00%</b>	<b>56.00%</b>	52.80%	52.80%
LIWC + SNA	NAÏVE BAYES	37.20%	<b>59.20%</b>	<b>65.60%</b>	44.00%	49.60%
	SVM	50.40%	55.20%	49.60%	45.20%	38.40%
	Logistic Regression	45.20%	54.00%	61.20%	49.20%	<b>58.00%</b>
	GRADIENT BOOSTING	<b>56.40%</b>	57.60%	59.60%	<b>59.60%</b>	57.60%
	LDA	55.60%	52.40%	62.80%	54.40%	52.80%
SPLICE + SNA	NAÏVE BAYES	41.20%	50.40%	60.80%	50.00%	43.60%
	SVM	50.40%	51.20%	54.40%	49.20%	49.60%
	Logistic Regression	56.80%	<b>54.80%</b>	<b>61.20%</b>	48.80%	<b>58.40%</b>
	GRADIENT BOOSTING	<b>61.20%</b>	48.00%	59.20%	<b>54.80%</b>	56.00%
	LDA	56.00%	54.40%	58.00%	52.40%	57.60%
LIWC + SPLICE + SNA	NAÏVE BAYES	41.20%	50.40%	<b>60.80%</b>	50.00%	43.20%
	SVM	50.40%	51.20%	54.40%	49.20%	52.00%
	Logistic Regression	56.40%	55.20%	<b>60.80%</b>	46.40%	59.20%
	GRADIENT BOOSTING	<b>58.00%</b>	51.60%	58.80%	52.00%	<b>60.40%</b>
	LDA	56.00%	<b>56.40%</b>	58.00%	<b>52.80%</b>	50.40%

**Tabel 4.9** Hasil Percobaan Skenario 6 dengan *Features Selection* dan *Oversampling*

Skenario 6 dengan hasil yang dapat dilihat pada tabel diatas semakin membuktikan bahwa penggunaan dua faktor skenario tidak

dapat meningkatkan akurasi secara signifikan. Bahkan tidak ada hasil akurasi yang memiliki akurasi tertinggi yang lebih tinggi daripada percobaan di skenario sebelumnya.

#### 4.2.3.2.7 Kesimpulan Hasil Implementasi *Machine learning* pada *Dataset myPersonality*

Berikut adalah tabel hasil kesimpulan dari semua skenario percobaan yang menggunakan *dataset myPersonality*.

<i>Traits</i>	<i>Accuracy</i>	<i>Algorithm</i>	<i>Skenario</i>	<i>Features</i>
<i>Openness</i>	70.4	SVM	Skenario 2	LIWC
		Logistic Regression	Skenario 1 Skenario 2	
<i>Conscientiousness</i>	59.2	Naïve Bayes	Skenario 4 Skenario 6	LIWC
			Skenario 4 Skenario 6	LIWC+SNA
<i>Extraversion</i>	68.8	Naïve Bayes	Skenario 1 Skenario 2	LIWC
			Skenario 1 Skenario 2	LIWC+SNA
<i>Agreeableness</i>	63.2	Gradient Boosting	Skenario 5	LIWC
<i>Neuroticism</i>	60.8	Linear Discriminant Analysis	Skenario 1	LIWC

**Tabel 4.10** Kesimpulan hasil implementasi *Machine learning* pada *Dataset myPersonality*

Dari Tabel kesimpulan 4.10 diatas dapat dilihat bahwa fitur LIWC merupakan fitur yang paling dominan untuk digunakan pada semua *traits* kepribadian *Big Five Personality*. Algoritma yang menjadi akurasi tertinggi cukup menyebar dan hanya Naïve Bayes



yang muncul dua kali sebagai algoritma terbaik untuk *traits Conscientiousness* dan *traits Extraversion*.

Untuk skenario di *dataset myPersonality* ini, dapat ditarik kesimpulan bahwa ternyata penambahan *Features Selection* dan proses *Resampling* tidak secara signifikan membantu hasil akurasi dari percobaan. Tiga *traits* yaitu, *Openness*, *Extraversion*, dan *Neuroticism* masih menggunakan skenario 1 yang tidak menambahkan proses *Features Selection* dan *Resampling*. *Traits Conscientiousness* dan *Agreeableness* juga hanya mengalami peningkatan beberapa persen dari skenario 1.

#### **4.2.3.3 Dataset Manual Gathering**

Percobaan dengan skenario 7-12 dilakukan dengan menggunakan *dataset* yang didapatkan secara manual oleh peneliti. Tujuan percobaan dengan *dataset* ini dilakukan secara terpisah untuk mencegah terjadinya ketidakseimbangan hasil penelitian yang menggabungkan *dataset* ini dengan *dataset myPersonality* (Kosinski, 2015), sehingga peneliti dapat melihat langsung akurasi yang diperoleh oleh *dataset* ini.

Percobaan dengan *dataset* ini juga akan menghilangkan penggunaan fitur SNA yang hanya disediakan oleh *dataset myPersonality*.

##### **4.2.3.3.1 Skenario 7 (Percobaan tanpa menggunakan *Features Selection* dan tanpa *Resampling*)**

Skenario 7 percobaan tanpa menggunakan *Features Selection* dan tanpa proses *Resampling* di *dataset* manual ini memiliki nilai akurasi cukup tinggi jika dibandingkan dengan percobaan sebelumnya yang menggunakan *dataset myPersonality*.

Hasil skenario terdapat pada Tabel 4.11 di bawah ini. Akurasi tertinggi untuk *traits Openness* adalah 67.33% dengan algoritma Gradient Boosting. Akurasi tertinggi untuk *traits Conscientiousness* juga 67.33% dengan LDA. Untuk *traits Extraversion*, akurasi tertinggi diperoleh dengan algoritma LDA setinggi 79.33%. *Traits Agreeableness* memiliki akurasi tertinggi yaitu 62.67% dengan

algoritma LDA. Akurasi tertinggi untuk *traits Neuroticism* diperoleh dengan algoritma SVM dengan nilai akurasi 69.33%.

**Tabel 4.11** Hasil Percobaan Skenario 7 tanpa *Features Selection* dan tanpa *Resampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	60.67%	62.67%	73.33%	52.00%	59.33%
	SVM	62.67%	65.33%	76.00%	56.67%	<b>69.33%</b>
	Logistic Regression	64.00%	57.33%	74.00%	<b>58.00%</b>	66.67%
	GRADIENT BOOSTING	<b>67.33%</b>	62.67%	70.67%	<b>58.00%</b>	66.67%
	LDA	58.00%	<b>67.33%</b>	<b>79.33%</b>	57.33%	57.33%
SPLICE	NAÏVE BAYES	42.00%	44.00%	<b>70.67%</b>	47.33%	43.33%
	SVM	60.67%	58.00%	46.67%	56.67%	43.33%
	Logistic Regression	<b>65.33%</b>	<b>66.00%</b>	66.00%	55.33%	56.00%
	GRADIENT BOOSTING	58.67%	57.33%	66.67%	<b>58.67%</b>	<b>58.67%</b>
	LDA	58.00%	61.33%	61.33%	54.00%	58.00%
LIWC + SPLICE	NAÏVE BAYES	42.00%	44.00%	69.33%	46.00%	44.00%
	SVM	58.00%	55.33%	47.33%	58.00%	54.00%
	Logistic Regression	66.00%	<b>66.00%</b>	65.33%	56.00%	57.33%
	GRADIENT BOOSTING	<b>67.33%</b>	61.33%	<b>72.00%</b>	56.00%	<b>65.33%</b>
	LDA	54.00%	47.33%	48.67%	<b>62.67%</b>	56.00%

#### 4.2.3.3.2 Skenario 8 (Percobaan dengan menggunakan *Features Selection*)

Skenario 8 mengimplementasikan *Features Selection* pada percobaan dengan *dataset* manual dan hasilnya ternyata tidak jauh lebih baik daripada skenario 7 dimana hanya *traits Neuroticism* yang mengalami peningkatan di akurasi tertingginya. Akurasi tertinggi yang didapatkan *Neuroticism* adalah 70% dengan algoritma Naïve Bayes. Akurasi tertinggi untuk *traits* selain *Neuroticism* masih lebih rendah dibanding skenario 7 yang tidak menggunakan

faktor skenario apapun. Hasil akurasi di skenario 8 terdapat pada Tabel 4.12 di bawah ini.

**Tabel 4.12** Hasil Percobaan Skenario 8 dengan *Features Selection*

<i>Features</i>	<b>Algorithm</b>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	52.67%	54.67%	72.67%	49.33%	<b>70.00%</b>
	SVM	<b>64.67%</b>	57.33%	74.67%	53.33%	66.67%
	Logistic Regression	<b>64.67%</b>	<b>58.00%</b>	74.67%	<b>54.00%</b>	66.67%
	GRADIENT BOOSTING	51.33%	48.67%	76.00%	52.00%	61.33%
	LDA	60.00%	57.33%	<b>78.00%</b>	<b>54.00%</b>	66.67%
SPLICE	NAÏVE BAYES	41.33%	44.00%	<b>70.00%</b>	46.67%	40.67%
	SVM	60.67%	54.00%	52.00%	55.33%	54.67%
	Logistic Regression	<b>65.33%</b>	<b>66.67%</b>	66.00%	<b>59.33%</b>	57.33%
	GRADIENT BOOSTING	61.33%	54.67%	68.00%	55.33%	57.33%
	LDA	56.67%	62.00%	64.00%	54.00%	<b>62.00%</b>
LIWC + SPLICE	NAÏVE BAYES	41.33%	44.00%	70.00%	46.67%	40.67%
	SVM	60.67%	54.00%	58.00%	55.33%	50.67%
	Logistic Regression	<b>66.67%</b>	<b>66.67%</b>	66.00%	<b>59.33%</b>	56.67%
	GRADIENT BOOSTING	62.00%	56.67%	72.67%	58.00%	<b>64.67%</b>
	LDA	54.67%	63.33%	<b>74.00%</b>	53.33%	64.00%

#### 4.2.3.3.3 Skenario 9 (Percobaan dengan menggunakan *Undersampling*)

Skenario 9 mengimplementasikan penggunaan salah satu proses *Resampling* yaitu *Undersampling* pada percobaan ini. Akurasi yang didapatkan ternyata menurun jika dibandingkan dengan skenario 7 yang tidak menggunakan proses *Resampling* ataupun *Features Selection*. Bahkan hasil di skenario 7 ini juga lebih rendah jika dibandingkan dengan skenario 8 yang menggunakan *Features Selection*. Tidak ada akurasi tertinggi dari hasil skenario ini yang

lebih tinggi dibandingkan dengan skenario sebelumnya. Hasil skenario 8 ada pada Tabel 4.13.

**Tabel 4.13** Hasil Percobaan Skenario 9 dengan *Undersampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	52.67%	58.00%	<b>67.33%</b>	50.67%	46.00%
	SVM	55.33%	58.67%	56.67%	56.00%	<b>59.33%</b>
	Logistic Regression	<b>62.00%</b>	54.00%	50.00%	57.33%	52.67%
	GRADIENT BOOSTING	53.33%	<b>62.00%</b>	52.67%	55.33%	50.67%
	LDA	54.67%	58.67%	58.00%	<b>60.67%</b>	52.00%
SPLICE	NAÏVE BAYES	41.33%	44.67%	<b>60.00%</b>	47.33%	40.67%
	SVM	46.00%	51.33%	56.00%	56.00%	53.33%
	Logistic Regression	<b>62.67%</b>	<b>62.00%</b>	59.33%	<b>58.00%</b>	52.00%
	GRADIENT BOOSTING	56.00%	57.33%	53.33%	56.00%	<b>58.00%</b>
	LDA	52.00%	57.33%	51.33%	50.67%	52.67%
LIWC + SPLICE	NAÏVE BAYES	40.67%	44.67%	<b>62.67%</b>	46.00%	42.00%
	SVM	51.33%	53.33%	56.00%	51.33%	51.33%
	Logistic Regression	<b>61.33%</b>	62.00%	58.00%	57.33%	53.33%
	GRADIENT BOOSTING	58.67%	<b>66.00%</b>	54.67%	<b>59.33%</b>	<b>59.33%</b>
	LDA	50.00%	64.67%	62.00%	46.00%	57.33%

#### 4.2.3.3.4 Skenario 10 (Percobaan dengan menggunakan *Oversampling*)

Percobaan dengan menggunakan *Oversampling* pada *dataset* manual ini memiliki akurasi yang cukup sebanding dengan skenario 7. Tidak ada hasil akurasi tertinggi yang lebih tinggi dibandingkan dengan semua skenario sebelumnya. Namun, akurasi di skenario 10 yang menggunakan *Oversampling* masih lebih baik dibandingkan hasil akurasi yang menggunakan *Undersampling* di skenario 9. Hasil skenario 10 ada pada Tabel 4.14 di bawah ini.

**Tabel 4.14** Hasil Percobaan Skenario 10 dengan *Oversampling*

<i>Features</i>	<b>Algorithm</b>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	52.67%	60.67%	73.33%	53.33%	46.00%
	SVM	62.00%	62.00%	68.00%	56.00%	<b>64.00%</b>
	Logistic Regression	61.33%	60.00%	67.33%	55.33%	60.67%
	GRADIENT BOOSTING	<b>67.33%</b>	62.67%	72.00%	57.33%	62.67%
	LDA	59.33%	<b>64.00%</b>	<b>78.00%</b>	<b>59.33%</b>	57.33%
SPLICE	NAÏVE BAYES	43.33%	44.00%	58.00%	47.33%	42.67%
	SVM	55.33%	60.67%	52.67%	57.33%	44.67%
	Logistic Regression	<b>62.67%</b>	<b>64.67%</b>	62.67%	56.67%	57.33%
	GRADIENT BOOSTING	62.00%	60.67%	<b>65.33%</b>	<b>58.00%</b>	<b>58.67%</b>
	LDA	56.00%	63.33%	54.67%	52.00%	54.67%
LIWC + SPLICE	NAÏVE BAYES	42.67%	43.33%	63.33%	46.67%	40.67%
	SVM	60.67%	60.67%	60.00%	56.00%	44.67%
	Logistic Regression	63.33%	66.00%	61.33%	56.00%	58.00%
	GRADIENT BOOSTING	<b>64.67%</b>	<b>66.67%</b>	<b>73.33%</b>	55.33%	<b>67.33%</b>
	LDA	52.67%	46.67%	48.67%	<b>62.67%</b>	56.67%

**4.2.3.3.5 Skenario 11 (Percobaan dengan menggunakan*****Features Selection* dan dengan *Undersampling*)**

Skenario 11 ini yang mencoba implementasi kedua algoritma yaitu *Features Selection* dan *Undersampling* juga tidak memiliki pengaruh dalam meningkatkan hasil akurasi. Terbukti dapat dilihat pada Tabel 4.15 di bawah ini dimana tidak ada satupun hasil akurasi tertinggi yang meningkat dari hasil di skenario 7.

**Tabel 4.15** Hasil Percobaan Skenario 11 dengan *Features Selection* dan *Undersampling*

<i>Features</i>	<b>Algorithm</b>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	43.33%	52.67%	51.33%	52.67%	60.00%
	SVM	47.33%	50.67%	<b>72.67%</b>	55.33%	<b>64.00%</b>

	Logistic Regression	<b>48.67%</b>	52.67%	69.33%	53.33%	<b>64.00%</b>
	GRADIENT BOOSTING	46.67%	<b>53.33%</b>	64.00%	52.67%	55.33%
	LDA	43.33%	49.33%	68.00%	<b>54.00%</b>	<b>64.00%</b>
SPLICE	NAÏVE BAYES	41.33%	43.33%	<b>60.00%</b>	46.00%	40.67%
	SVM	54.67%	54.00%	50.67%	<b>60.67%</b>	46.00%
	Logistic Regression	<b>62.00%</b>	<b>62.67%</b>	52.00%	58.67%	52.67%
	GRADIENT BOOSTING	58.00%	61.33%	51.33%	52.00%	<b>53.33%</b>
	LDA	56.67%	60.00%	48.00%	50.00%	<b>55.33%</b>
LIWC + SPLICE	NAÏVE BAYES	41.33%	43.33%	60.67%	46.00%	40.67%
	SVM	54.00%	54.00%	56.00%	57.33%	48.67%
	Logistic Regression	<b>61.33%</b>	62.67%	50.67%	58.67%	53.33%
	GRADIENT BOOSTING	52.67%	56.00%	59.33%	<b>60.67%</b>	62.00%
	LDA	54.67%	<b>64.67%</b>	<b>64.00%</b>	55.33%	<b>64.00%</b>

#### 4.2.3.3.6 Skenario 12 (Percobaan dengan menggunakan

##### *Features Selection dan dengan Oversampling)*

Skenario 12 memiliki hasil yang cukup sebanding dengan skenario 11 dalam hasil akurasi secara keseluruhan. Skenario 12 juga tidak memiliki akurasi tertinggi dari setiap *traits* yang lebih tinggi dari hasil akurasi tertinggi pada skenario 7. Hasil skenario 12 dapat dilihat pada tabel di bawah ini.

**Tabel 4.16** Hasil Percobaan Skenario 12 dengan *Features Selection* dan *Oversampling*

<i>Features</i>	<b>Algorithm</b>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	45.33%	<b>54.00%</b>	66.00%	50.00%	62.67%
	SVM	47.33%	48.00%	68.67%	56.67%	62.00%
	Logistic Regression	47.33%	49.33%	66.00%	<b>59.33%</b>	62.67%
	GRADIENT BOOSTING	<b>53.33%</b>	48.67%	70.00%	52.67%	59.33%
	LDA	42.67%	51.33%	<b>70.67%</b>	52.00%	<b>63.33%</b>
SPLICE	NAÏVE BAYES	42.67%	42.67%	57.33%	46.67%	40.00%
	SVM	54.00%	58.00%	53.33%	54.00%	41.33%

	Logistic Regression	63.33%	66.67%	59.33%	59.33%	56.67%
	GRADIENT BOOSTING	60.67%	62.00%	66.67%	54.67%	60.67%
	LDA	54.67%	62.00%	53.33%	54.67%	56.00%
LIWC + SPLICE	NAÏVE BAYES	43.33%	42.67%	58.00%	47.33%	40.00%
	SVM	50.00%	60.00%	56.67%	56.00%	41.33%
	Logistic Regression	66.00%	66.00%	59.33%	58.00%	57.33%
	GRADIENT BOOSTING	66.00%	58.67%	72.00%	60.67%	60.00%
	LDA	52.00%	64.00%	70.67%	56.67%	63.33%

#### 4.2.3.3.7 Kesimpulan Hasil Implementasi *Machine learning* pada *Dataset Manual Gathering*

<i>Traits</i>	<i>Accuracy</i>	<i>Algorithm</i>	<i>Skenario</i>	<i>Features</i>
<i>Openness</i>	67.33	Gradient Boosting	Skenario 7	LIWC+SPLICE
			Skenario 7 Skenario 10	LIWC
<i>Conscientiousness</i>	67.33	Linear Discriminant Analysis	Skenario 7	LIWC
<i>Extraversion</i>	79.33	Linear Discriminant Analysis	Skenario 7	LIWC
<i>Agreeableness</i>	62.67	Linear Discriminant Analysis	Skenario 7 Skenario 10	LIWC+SPLICE
<i>Neuroticism</i>	70	Naïve Bayes	Skenario 8	LIWC

**Tabel 4.17** Kesimpulan hasil implementasi *Machine learning* pada *Dataset Manual Gathering*

Dari tabel kesimpulan diatas dapat dilihat bahwa ternyata benar bahwa skenario yang tidak menggunakan proses *Features Selection* dan *Resampling* masih mendominasi akurasi tertinggi seperti pada *dataset* manual ini dimana semua *traits* memiliki akurasi tertinggi jika menggunakan skenario 7 kecuali *Neuroticism* yang

mendapatkan akurasi tertinggi dengan skenario 8 yang menggunakan *Features Selection*. Fitur yang paling mendominasi di *dataset* ini masih merupakan fitur LIWC dimana digunakan di semua *traits*. Untuk algoritma, Linear Discriminant Analysis mendominasi dengan menjadi akurasi tertinggi bagi 3 *traits* yaitu, *Conscientiousness*, *Extraversion*, dan *Agreeableness*.

Jika dibandingkan dengan hasil percobaan skenario 1-6 yang menggunakan *dataset myPersonality*, akurasi tertinggi di *dataset* manual ini lebih tinggi untuk *traits Conscientiousness* (67.33% dibandingkan dengan 59.2%), *Extraversion* (79.33% dibandingkan dengan 68.8%), dan *Neuroticism* (70% dibandingkan dengan 60.8%). Sedangkan dua *traits* lainnya diungguli oleh *myPersonality*, *Openness* (67.33% dibandingkan dengan 70.4%) dan *Agreeableness* (62.67% dibandingkan dengan 63.2%).

#### 4.2.3.4 Dataset Gabungan

Percobaan dengan skenario 13-18 dilakukan dengan menggunakan *dataset* gabungan dari *dataset myPersonality* dan *dataset Manual Gathering* yang berjumlah 400 *dataset*. Jika sebelumnya percobaan dilakukan untuk masing-masing *dataset* untuk mencegah terjadinya ketidakseimbangan data bila digabungkan, maka untuk percobaan kali ini, peneliti mencoba menggabungkan kedua *dataset* tersebut dan melihat bagaimana hasil akurasinya jika dibandingkan dengan *dataset* sebelum digabungkan.

Peneliti ingin mengetahui apakah dengan jumlah data yang lebih besar dapat menghasilkan proses learning dan akurasi yang lebih baik atau sebaliknya karena menggunakan *dataset* gabungan yang berkemungkinan menjadi tidak seimbang dan membuat akurasi hasil percobaan semakin menurun.

##### 4.2.3.4.1 Skenario 13 (Percobaan tanpa menggunakan *Features Selection* dan tanpa *Resampling*)



**Tabel 4.18** Hasil Percobaan Skenario 13 tanpa *Features Selection* dan tanpa *Resampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	61.50%	55.50%	62.00%	52.00%	49.25%
	SVM	67.25%	<b>58.75%</b>	66.50%	54.50%	<b>62.50%</b>
	Logistic Regression	<b>68.50%</b>	54.25%	66.25%	51.00%	<b>62.50%</b>
	GRADIENT BOOSTING	65.25%	57.25%	64.25%	55.75%	59.75%
	LDA	62.50%	58.00%	<b>68.50%</b>	<b>56.00%</b>	55.00%
SPLICE	NAÏVE BAYES	34.50%	50.25%	61.25%	46.50%	40.75%
	SVM	44.75%	51.50%	52.00%	<b>52.50%</b>	48.75%
	Logistic Regression	63.00%	52.25%	<b>63.25%</b>	48.50%	61.25%
	GRADIENT BOOSTING	61.50%	54.50%	60.75%	50.00%	57.25%
	LDA	<b>64.25%</b>	<b>56.25%</b>	60.00%	51.25%	<b>63.75%</b>
LIWC + SPLICE	NAÏVE BAYES	35.00%	50.50%	61.50%	46.00%	40.00%
	SVM	58.25%	49.25%	58.00%	48.75%	52.25%
	Logistic Regression	<b>63.50%</b>	55.00%	62.50%	47.75%	<b>63.75%</b>
	GRADIENT BOOSTING	<b>63.50%</b>	56.25%	62.50%	<b>56.50%</b>	59.50%
	LDA	58.00%	<b>59.25%</b>	<b>64.25%</b>	54.75%	59.25%

Skenario 13 merupakan percobaan tanpa menggunakan *Features Selection* maupun proses *Resampling*. Hasil akurasi yang didapatkan tidak terlalu tinggi jika dibandingkan dengan percobaan yang menggunakan *dataset* terpisah. Akurasi tertinggi untuk *traits Openness* adalah 68.5% dengan algoritma Logistic Regression, *Conscientiousness* memiliki akurasi tertinggi 59.25% dengan LDA, *Extraversion* memiliki akurasi tertinggi 68.5% dengan algoritma LDA, *Agreeableness* hanya mencapai 56.5% dengan algoritma Gradient Boosting, dan *Neuroticism* memiliki akurasi tertinggi 63.75% dengan LDA dan Logistic Regression. Hasil skenario 13 dapat dilihat pada Tabel 4.18.

#### 4.2.3.4.2 Skenario 14 (Percobaan dengan menggunakan *Features Selection*)

Tabel 4.19 di bawah ini menunjukkan bahwa meski dengan menggunakan *Features Selection* untuk *dataset* gabungan ini, hasil akurasi tidak dapat bertambah secara signifikan. Hanya pada *traits Neuroticism*, akurasi hanya meningkat 1.50% dari skenario 13.

**Tabel 4.19** Hasil Percobaan Skenario 14 dengan *Features Selection*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	65.50%	51.25%	63.50%	45.50%	57.00%
	SVM	68.00%	52.25%	66.25%	52.50%	62.25%
	Logistic Regression	<b>68.25%</b>	50.25%	<b>66.50%</b>	53.75%	<b>62.75%</b>
	GRADIENT BOOSTING	62.00%	52.50%	59.50%	54.75%	56.25%
	LDA	68.00%	<b>54.25%</b>	66.25%	<b>55.25%</b>	61.50%
SPLICE	NAÏVE BAYES	34.25%	51.00%	60.75%	46.25%	39.50%
	SVM	58.25%	54.75%	54.75%	50.25%	49.00%
	Logistic Regression	63.00%	54.25%	64.50%	49.25%	62.00%
	GRADIENT BOOSTING	62.25%	54.25%	58.50%	<b>51.75%</b>	59.50%
	LDA	<b>63.50%</b>	<b>58.50%</b>	<b>61.50%</b>	51.50%	<b>65.25%</b>
LIWC + SPLICE	NAÏVE BAYES	34.00%	51.00%	61.25%	46.00%	39.25%
	SVM	53.50%	51.50%	50.50%	<b>53.50%</b>	48.25%
	Logistic Regression	<b>63.25%</b>	55.00%	<b>64.25%</b>	49.50%	62.00%
	GRADIENT BOOSTING	63.00%	55.75%	57.00%	53.25%	57.25%
	LDA	62.50%	<b>58.75%</b>	63.00%	52.00%	<b>65.00%</b>

#### 4.2.3.4.3 Skenario 15 (Percobaan dengan menggunakan *Undersampling*)

Penerapan proses *Undersampling* pada *dataset* ini juga ternyata membuat akurasi semakin menurun. Hal ini semakin menguatkan kesimpulan jika penggunaan *Undersampling* tidak dapat membantu *dataset* manapun dalam penelitian ini yang tergolong cukup kecil.

Dapat dilihat pada Tabel 4.20 di bawah, tidak ada akurasi tertinggi yang mampu mengungguli hasil akurasi skenario 13 tanpa proses apapun kecuali *traits Agreeableness* yang hanya unggul 0.25% dengan algoritma Gradient Boosting.

**Tabel 4.20** Hasil Percobaan Skenario 15 dengan *Undersampling*

<i>Features</i>	<b>Algorithm</b>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	39.75%	55.50%	49.25%	54.25%	39.50%
	SVM	42.50%	58.75%	52.25%	52.75%	<b>52.50%</b>
	Logistic Regression	46.25%	58.50%	50.75%	51.50%	50.00%
	GRADIENT BOOSTING	<b>49.00%</b>	55.75%	52.00%	<b>56.75%</b>	50.50%
	LDA	46.00%	<b>59.50%</b>	<b>59.75%</b>	56.00%	49.50%
SPLICE	NAÏVE BAYES	36.75%	50.50%	<b>59.75%</b>	46.75%	41.00%
	SVM	47.25%	51.25%	45.00%	49.50%	53.50%
	Logistic Regression	48.25%	52.00%	52.50%	50.75%	51.50%
	GRADIENT BOOSTING	47.50%	<b>56.00%</b>	47.25%	<b>52.00%</b>	50.75%
	LDA	<b>49.50%</b>	55.25%	49.25%	51.75%	<b>54.75%</b>
LIWC + SPLICE	NAÏVE BAYES	37.75%	50.50%	<b>61.00%</b>	46.75%	41.00%
	SVM	49.00%	50.50%	48.25%	51.25%	51.00%
	Logistic Regression	47.50%	54.25%	52.25%	50.00%	53.75%
	GRADIENT BOOSTING	48.00%	<b>58.25%</b>	56.25%	<b>56.00%</b>	53.75%
	LDA	<b>54.50%</b>	57.75%	60.00%	53.75%	<b>56.00%</b>

#### 4.2.3.4.4 Skenario 16 (Percobaan dengan menggunakan *Oversampling*)

Percobaan skenario 16 yang menggunakan *Oversampling* memperlihatkan hasil yang lebih baik dibandingkan dengan proses *Undersampling*. Ini terbukti dari hasil pada Tabel 4.21 dimana semua *traits* mengalami peningkatan akurasi.

Jika dibandingkan dengan skenario 13 yang tidak menggunakan proses apapun, penggunaan *Oversampling* cukup sebanding karena lebih unggul di dua *traits* yaitu, *Openness* dan *Agreeableness*.

**Tabel 4.21** Hasil Percobaan Skenario 16 dengan *Oversampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	50.25%	55.00%	55.00%	53.25%	41.00%
	SVM	<b>57.25%</b>	<b>60.75%</b>	58.50%	52.75%	54.00%
	Logistic Regression	56.50%	57.50%	53.50%	47.75%	<b>56.50%</b>
	GRADIENT BOOSTING	57.00%	59.25%	<b>65.25%</b>	<b>58.25%</b>	54.25%
	LDA	57.00%	59.25%	64.75%	56.50%	53.00%
SPLICE	NAÏVE BAYES	37.00%	50.50%	<b>60.50%</b>	46.25%	39.50%
	SVM	<b>61.25%</b>	50.50%	49.50%	51.00%	55.50%
	Logistic Regression	54.25%	52.00%	53.25%	49.00%	51.50%
	GRADIENT BOOSTING	60.00%	54.75%	56.50%	48.50%	56.00%
	LDA	54.25%	<b>55.25%</b>	52.00%	<b>52.25%</b>	<b>56.75%</b>
LIWC + SPLICE	NAÏVE BAYES	36.75%	50.75%	60.75%	45.00%	38.75%
	SVM	57.25%	51.25%	44.00%	<b>55.00%</b>	56.25%
	Logistic Regression	55.00%	54.75%	56.50%	49.75%	52.25%
	GRADIENT BOOSTING	<b>61.50%</b>	<b>59.75%</b>	<b>62.25%</b>	54.75%	<b>57.75%</b>
	LDA	54.75%	58.75%	59.50%	53.50%	56.00%

**4.2.3.4.5 Skenario 17 (Percobaan dengan menggunakan*****Features Selection* dan dengan *Undersampling*)**

Skenario 17 yang menggunakan *Features Selection* dan *Undersampling* untuk diterapkan pada *dataset* gabungan ini berbanding lurus dengan penggunaan *Undersampling* dimana akurasi malah mengalami penurunan di hampir semua *traits*. Hasil akurasi dapat dilihat pada Tabel 4.22 di bawah ini.

**Tabel 4.22** Hasil Percobaan Skenario 17 dengan *Features Selection* dan *Undersampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	<b>55.75%</b>	52.00%	<b>63.50%</b>	45.75%	37.50%

	SVM	51.75%	50.75%	58.25%	52.75%	51.25%
	Logistic Regression	51.75%	49.75%	57.00%	54.50%	52.00%
	GRADIENT BOOSTING	49.00%	51.50%	51.00%	53.00%	<b>52.50%</b>
	LDA	49.50%	<b>53.50%</b>	57.50%	<b>57.00%</b>	51.75%
SPLICE	NAÏVE BAYES	36.75%	51.25%	<b>59.25%</b>	47.25%	41.00%
	SVM	49.75%	50.25%	53.50%	<b>54.25%</b>	54.50%
	Logistic Regression	48.50%	52.75%	51.50%	50.25%	51.25%
	GRADIENT BOOSTING	47.25%	<b>56.25%</b>	47.25%	51.50%	51.00%
	LDA	<b>50.25%</b>	56.00%	48.00%	50.50%	<b>55.50%</b>
LIWC + SPLICE	NAÏVE BAYES	37.00%	51.00%	<b>59.25%</b>	47.00%	40.75%
	SVM	46.75%	53.25%	43.50%	51.25%	54.50%
	Logistic Regression	47.75%	53.50%	51.50%	50.75%	51.50%
	GRADIENT BOOSTING	48.25%	57.00%	50.50%	<b>53.50%</b>	50.75%
	LDA	<b>48.50%</b>	<b>58.50%</b>	50.00%	52.25%	<b>58.25%</b>

#### 4.2.3.4.6 Skenario 18 (Percobaan dengan menggunakan *Features Selection* dan dengan *Oversampling*)

Penambahan proses gabungan *Features Selection* dan *Oversampling* juga tidak mengalami peningkatan akurasi secara signifikan. Hanya *traits Agreeableness* yang meningkat sebanyak 1.50% dari skenario 13 yang tidak menggunakan proses apapun. Selain itu, semua *traits* mengalami penurunan akurasi. Hasil akurasi pada skenario ini dapat dilihat pada Tabel 4.23.

**Tabel 4.23** Hasil Percobaan Skenario 18 dengan *Features Selection* dan *Oversampling*

<i>Features</i>	<i>Algorithm</i>	<b>O</b>	<b>C</b>	<b>E</b>	<b>A</b>	<b>N</b>
LIWC	NAÏVE BAYES	<b>61.75%</b>	<b>52.25%</b>	<b>64.25%</b>	45.50%	43.25%
	SVM	52.75%	50.50%	60.00%	55.50%	53.75%
	Logistic Regression	54.25%	49.25%	57.25%	54.50%	<b>56.25%</b>
	GRADIENT BOOSTING	56.50%	51.50%	53.00%	55.75%	51.50%
	LDA	53.00%	52.00%	59.25%	<b>58.00%</b>	53.25%

SPLICE	NAÏVE BAYES	37.25%	51.00%	<b>60.50%</b>	46.25%	39.00%
	SVM	51.25%	54.75%	52.00%	49.25%	53.50%
	Logistic Regression	55.00%	54.25%	53.00%	<b>50.75%</b>	53.75%
	GRADIENT BOOSTING	<b>57.50%</b>	55.00%	54.25%	<b>50.75%</b>	55.00%
	LDA	53.00%	<b>57.50%</b>	54.00%	50.25%	<b>56.50%</b>
LIWC + SPLICE	NAÏVE BAYES	37.25%	51.00%	<b>60.75%</b>	46.00%	38.50%
	SVM	50.25%	50.25%	57.25%	53.25%	51.75%
	Logistic Regression	54.50%	55.50%	54.50%	51.00%	54.75%
	GRADIENT BOOSTING	<b>59.75%</b>	54.50%	57.00%	<b>53.75%</b>	58.50%
	LDA	53.50%	<b>58.50%</b>	54.00%	51.00%	<b>59.25%</b>

#### 4.2.3.4.7 Kesimpulan hasil implementasi *Machine learning* pada *Dataset Gabungan*

Dari tabel kesimpulan dibawah, dapat dilihat bahwa ternyata setelah *dataset* digabungkan, tidak terjadi peningkatan akurasi secara signifikan. Hasil yang dapat dilihat pada Tabel 4.24 menunjukkan tidak ada *traits* yang memiliki akurasi lebih tinggi dibandingkan dengan percobaan yang menggunakan *dataset* terpisah. Akurasi tertinggi yang didapatkan adalah *traits Openness* dengan nilai 68.5% menggunakan algoritma Logistic Regression dan *Extraversion* juga dengan nilai 68.5 menggunakan algoritma Linear Discriminant Analysis.

<i>Traits</i>	<i>Accuracy</i>	<i>Algorithm</i>	<i>Skenario</i>	<i>Features</i>
<i>Openness</i>	68.5	Logistic Regression	Skenario 13	LIWC
<i>Conscientiousness</i>	60.75	Support Vector Machine	Skenario 16	LIWC
<i>Extraversion</i>	68.5	Linear Discriminant Analysis	Skenario 13	LIWC
<i>Agreeableness</i>	58.25	Gradient Boosting	Skenario 16	LIWC

<i>Neuroticism</i>	65.25	Linear Discriminant Analysis	Skenario 14	SPLICE
--------------------	-------	------------------------------	-------------	--------

**Tabel 4.24** Kesimpulan hasil implementasi *Machine learning* pada *Dataset Gabungan*

#### 4.2.3.5 Kesimpulan Implementasi *Machine learning*

Setelah melakukan implementasi metode *Machine learning* pada tiga *dataset* berbeda dengan 6 skenario di masing-masing *dataset* tersebut. Peneliti membuat sebuah kesimpulan yang diperoleh dari seluruh percobaan tersebut. Seluruh akurasi tertinggi yang didapatkan dikumpulkan dan digabungkan menjadi 1. Akurasi tertinggi dengan nilai yang sama akan diutamakan dengan yang menggunakan proses skenario paling sedikit yaitu tidak menggunakan proses sama sekali.

**Tabel 4.25** Kesimpulan hasil implementasi *Machine learning*

<i>Traits</i>	<i>Accuracy</i>	<i>Algorithm</i>	<i>Proses</i>	<i>Features</i>
<i>Openness</i>	70.4	Logistic Regression	Tanpa <i>Features Selection</i> dan Tanpa <i>Resampling</i>	LIWC
<i>Conscientiousness</i>	67.33	Linear Discriminant Analysis	Tanpa <i>Features Selection</i> dan Tanpa <i>Resampling</i>	LIWC
<i>Extraversion</i>	79.33	Linear Discriminant Analysis	Tanpa <i>Features Selection</i> dan Tanpa <i>Resampling</i>	LIWC
<i>Agreeableness</i>	63.2	Gradient Boosting	<i>Features Selection</i> dan <i>Undersampling</i>	LIWC
<i>Neuroticism</i>	70	Naïve Bayes	<i>Features Selection</i>	LIWC

Dari Tabel 4.25 di atas dapat dilihat bahwa fitur LIWC menjadi fitur paling dominan untuk mendapatkan akurasi yang paling tinggi di implementasi *Machine learning* pada penelitian ini. Faktor Skenario yang berupa dua proses yaitu *Features Selection* dan *Resampling* yang dicoba

untuk diterapkan dalam penelitian kali ini ternyata tidak memiliki pengaruh besar terhadap peningkatan akurasi. Dari semua tabel kesimpulan di masing-masing *dataset* sebelumnya, hasil akurasi tertinggi didominasi oleh skenario yang tidak menggunakan proses apapun, begitu juga dengan tabel diatas dimana tiga *traits* yaitu, *Openness*, *Conscientiousness*, dan *Extraversion* memiliki akurasi paling tinggi di implementasi *Machine learning* tanpa menggunakan *Features Selection* dan *Resampling* apapun. Sedangkan untuk *traits Agreeableness* menggunakan *Features Selection* dan *Undersampling* untuk mendapatkan akurasi 63.2% dan hanya lebih tinggi 0.53% dari hasil yang tidak menggunakan proses apapun. *Traits Neuroticism* mendapatkan akurasi tertinggi yaitu 70% dengan menggunakan *Features Selection* dan unggul cukup signifikan sebanyak 9.20% dari hasil yang tidak menggunakan proses apapun.

Untuk kesimpulan algoritma yang digunakan, Linear Discriminant Analysis atau LDA menjadi salah satu algoritma yang paling dominan dengan selalu muncul di setiap tabel kesimpulan masing-masing *dataset*. LDA mendapatkan akurasi tertinggi di implementasi *Machine learning* untuk dua *traits* kepribadian yaitu, *Conscientiousness* dengan akurasi 67.33% dan *Extraversion* dengan akurasi 79.33%. Untuk *traits Openness* menggunakan algoritma Logistic Regression dengan hasil akurasi 70.4%, *traits Agreeableness* dengan algoritma Gradient Boosting dan mendapatkan hasil akurasi 63.2%, serta *traits* terakhir yaitu *Neuroticism* yang memperoleh 70% dengan algoritma Naïve Bayes. Jadi, masing-masing algoritma ternyata memiliki kelebihan di masing-masing *traits* dan tidak ada satu algoritma tertentu yang berpengaruh sangat besar terhadap hasil akurasi dari semua *traits* penelitian ini.

Hasil yang didapatkan dari implementasi *Machine learning* ini akan dibandingkan dengan hasil dari implementasi *Deep learning* untuk menentukan algoritma, fitur dan proses yang akan diterapkan di hasil akhir aplikasi sistem prediksi kepribadian.



## 4.2.4 Implementasi *Deep learning*

### 4.2.4.1 Skenario

Implementasi *deep learning* pada *testing* kali ini akan menggunakan 4 model arsitektur yaitu MultiLayer Perceptron (MLP), LSTM, CNN dan GRU. Sebagai tambahan dari referensi, implementasi *Deep learning* kali ini akan menggunakan arsitektur tambahan yaitu gabungan dari CNN dan LSTM. Fitur yang digunakan dalam implementasi *Deep learning* hanya dengan metode *Open Vocabulary*. Proses *testing* pada *Deep learning* juga akan diaplikasikan ke masing-masing *dataset* berbeda seperti halnya implementasi *Machine learning* pada Bagian 4.2.3 diatas. Distribusi data yang akan digunakan dapat kembali di lihat di Bagian 4.2.1.

Dari faktor skenario diatas pada Bagian 4.2.2, *deep learning* hanya akan menggunakan satu faktor tersebut yaitu *Resampling* (Bagian 4.2.2.2) yang terbagi menjadi dua proses yaitu *Undersampling* dan *Oversampling*, sehingga dapat dibentuk skenario percobaan untuk *deep learning* sebagai berikut:

1. Penggunaan *Dataset myPersonality*, percobaan tanpa menggunakan *Resampling*.
2. Penggunaan *Dataset myPersonality*, percobaan dengan menggunakan *Undersampling*.
3. Penggunaan *Dataset myPersonality*, percobaan dengan menggunakan *Oversampling*.
4. Penggunaan *Dataset Manual Gathering*, percobaan tanpa menggunakan *Resampling*.
5. Penggunaan *Dataset Manual Gathering*, percobaan dengan menggunakan *Undersampling*.
6. Penggunaan *Dataset Manual Gathering*, percobaan dengan menggunakan *Oversampling*.
7. Penggunaan *Dataset Gabungan*, percobaan tanpa menggunakan *Resampling*.
8. Penggunaan *Dataset Gabungan*, percobaan dengan menggunakan *Undersampling*.

9. Penggunaan *Dataset* Gabungan, percobaan dengan menggunakan *Oversampling*.

Keterangan pada tabel percobaan:

	= Header Tabel percobaan yang menggunakan <i>dataset myPersonality</i>
	= Header Tabel percobaan yang menggunakan <i>dataset Manual Gathering</i>
	= Header Tabel percobaan yang menggunakan <i>dataset gabungan</i>

O = *Traits Openness*

C = *Traits Conscientiousness*

E = *Traits Extraversion*

A = *Traits Agreeableness*

N = *Traits Neuroticism*

**Highlight** = Akurasi tertinggi pada sebuah *Traits*

#### 4.2.4.2 *Dataset myPersonality*

Percobaan dengan implementasi *Deep learning* skenario 1-3 akan menggunakan *dataset myPersonality*.

##### 4.2.4.2.1 Skenario 1 (Percobaan tanpa menggunakan *Resampling*)

Arsitektur	O	C	E	A	N
MLP	<b>68.00%</b>	58.00%	56.00%	42.00%	62.00%
LSTM	<b>68.00%</b>	52.00%	58.00%	<b>52.00%</b>	58.00%
GRU	<b>68.00%</b>	<b>62.00%</b>	58.00%	50.00%	<b>64.00%</b>
CNN 1D	62.00%	46.00%	56.00%	<b>52.00%</b>	58.00%
CNN 1D+LSTM	64.00%	46.00%	<b>60.00%</b>	42.00%	58.00%

**Tabel 4.26** Hasil Percobaan Skenario 1 tanpa proses *Resampling*

Percobaan skenario 1 yang tidak menggunakan proses *Resampling* dapat dilihat pada Tabel 4.26 di atas. Dari hasil tersebut dapat dilihat bahwa penggunaan metode *Deep learning* menghasilkan hasil akurasi yang cukup seimbang, arsitektur *Deep learning* GRU menjadi yang paling dominan sebagai akurasi tertinggi untuk tiga *traits* yaitu, *Openness* dengan 68%, *Conscientiousness* dengan 62%, dan *Neuroticism* dengan 64%. Untuk *traits Extraversion*, arsitektur dengan akurasi paling baik adalah gabungan arsitektur CNN 1D+LSTM. Sedangkan untuk *traits Agreeableness*, akurasi tertinggi yang dapat dicapai adalah 52% dengan menggunakan arsitektur LSTM dan arsitektur CNN 1D.

#### 4.2.4.2.2 Skenario 2 (Percobaan dengan menggunakan *Undersampling*)

Arsitektur	O	C	E	A	N
MLP	79.31%	50.00%	78.95%	56.52%	79.49%
LSTM	44.83%	45.83%	57.89%	56.52%	56.41%
GRU	31.03%	54.17%	44.74%	65.22%	48.72%
CNN 1D	79.31%	47.92%	57.89%	67.39%	61.54%
CNN 1D+LSTM	75.86%	47.92%	71.05%	43.48%	58.97%

**Tabel 4.27** Hasil Percobaan Skenario 2 dengan Proses *Undersampling*

Percobaan di skenario ke 2 ini menggunakan Proses *Undersampling*. Pada Tabel 4.27 di atas dapat dilihat bahwa rata-rata hasil akurasi meningkat dengan Proses *Resampling* ini. Akurasi tertinggi pada *traits Openness* adalah 79.31% didapatkan dengan arsitektur MLP dan arsitektur CNN 1D. Hasil ini meningkat 11.31% dari akurasi tertinggi yang didapat pada skenario 1. Untuk *traits Conscientiousness*, akurasi tertinggi mengalami penurunan menjadi 54.17% dari 62% pada skenario 1 dengan arsitektur yang sama yaitu GRU. *Traits Extraversion* juga mengalami peningkatan akurasi

menjadi 78.95% dengan arsitektur MLP dan meningkat 18.95% dibandingkan tanpa menggunakan proses *Resampling*. *Agreeableness* mendapatkan akurasi tertinggi yaitu 67.39%, juga meningkat secara signifikan sebesar 15.39% dari hasil akurasi pada skenario 1. Arsitektur yang digunakan juga CNN 1D pada *traits Agreeableness* ini. Untuk *traits Neuroticism*, pencapaian akurasi tertinggi adalah 79.49% dengan arsitektur MLP, meningkat 15.49% dari skenario 1 yang menggunakan arsitektur GRU tanpa proses *Resampling*.

Hasil pada skenario 2 dengan proses *Undersampling* didominasi oleh arsitektur MLP dengan semua akurasi tertinggi berada di nilai >75%.

#### 4.2.4.2.3 Skenario 3 (Percobaan dengan menggunakan *Oversampling*)

Arsitektur	O	C	E	A	N
MLP	54.41%	59.62%	53.33%	50.00%	38.89%
LSTM	48.53%	51.92%	57.14%	53.85%	58.62%
GRU	52.94%	59.62%	48.21%	48.08%	56.90%
CNN 1D	50.00%	50.00%	60.94%	50.00%	40.74%
CNN 1D+LSTM	60.29%	57.69%	50.00%	50.00%	53.45%

**Tabel 4.28** Hasil Percobaan Skenario 3 dengan Proses *Oversampling*

Percobaan pada skenario 3 dengan proses *Oversampling* mengalami penurunan sedikit dibandingkan skenario 1 dan perbedaan akurasi tertinggi cukup signifikan jika dibandingkan dengan skenario 2 yang menggunakan *Undersampling*. Pencapaian akurasi tertinggi yang berhasil diperoleh hanya sebesar 60.94% untuk *traits Extraversion* dengan menggunakan arsitektur CNN 1D. Akurasi tertinggi kedua adalah *traits Openness* sebesar 60.29%

dengan arsitektur CNN 1D+LSTM. Akurasi tertinggi lainnya memiliki nilai lebih kecil dari 60%.

#### 4.2.4.2.4 Kesimpulan Hasil Implementasi *Deep learning* pada *Dataset myPersonality*

<i>Traits</i>	<i>Accuracy</i>	<i>Arsitektur</i>	<i>Skenario</i>
<i>Openness</i>	79.31	MLP	Skenario 2
		CNN 1D	
<i>Conscientiousness</i>	62	GRU	Skenario 1
<i>Extraversion</i>	78.95	MLP	Skenario 2
<i>Agreeableness</i>	67.39	CNN 1D	Skenario 2
<i>Neuroticism</i>	79.49	MLP	Skenario 2

**Tabel 4.29** Kesimpulan hasil implementasi *Deep learning* pada *Dataset myPersonality*

Dari tabel kesimpulan diatas, dapat dilihat bahwa penggunaan proses *Undersampling* sangat membantu dalam meningkatkan hasil akurasi pada implementasi metode *Deep learning*. Ini terbukti dengan penggunaan proses *Undersampling* menghasilkan akurasi tertinggi pada 4 *traits* yaitu *Openness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Sedangkan penggunaan proses *Oversampling* ternyata tidak membantu dalam meningkatkan hasil akurasi. Arsitektur yang mendapatkan akurasi tertinggi juga beragam, seperti MLP, CNN 1D dan GRU yang mendapatkan akurasi tertinggi di masing-masing *traits*.

#### 4.2.4.3 Dataset Manual Gathering

Percobaan dengan implementasi *Deep learning* skenario 4-6 akan menggunakan *dataset Manual Gathering*.

##### 4.2.4.3.1 Skenario 4 (Percobaan tanpa menggunakan *Resampling*)

Arsitektur	O	C	E	A	N
MLP	66.67%	56.67%	80.00%	53.33%	73.33%
LSTM	63.33%	53.33%	70.00%	53.33%	73.33%
GRU	63.33%	56.67%	70.00%	46.67%	76.67%
CNN 1D	50.00%	60.00%	73.33%	63.33%	66.67%
CNN 1D+LSTM	66.67%	66.67%	73.33%	63.33%	63.33%

**Tabel 4.30** Hasil Percobaan Skenario 4 tanpa Proses *Oversampling*

Skenario 4 yang tidak menggunakan proses *Oversampling* pada *dataset* manual ini memiliki akurasi yang cukup tinggi dengan rata-rata akurasi diatas 60%. Bahkan akurasi tertinggi untuk *traits Extraversion* mencapai 80% dengan arsitektur MLP. Arsitektur MLP juga mendapatkan hasil akurasi tertinggi untuk *traits Openness* dengan 66.67%. Untuk *traits Conscientiousness*, akurasi tertinggi didapat dengan arsitektur CNN 1D+LSTM dengan nilai 66.67%, *traits Agreeableness* mendapatkan akurasi tertinggi 63.33% juga dengan arsitektur CNN 1D+LSTM dan juga arsitektur yang hanya menggunakan CNN 1D. Untuk *traits Neuroticism*, hasil akurasi tertinggi mencapai 76.67% dengan arsitektur GRU.

#### 4.2.4.3.2 Skenario 5 (Percobaan dengan menggunakan *Undersampling*)

Arsitektur	O	C	E	A	N
MLP	66.67%	64.00%	93.33%	70.37%	75.00%
LSTM	61.90%	64.00%	66.67%	66.67%	75.00%
GRU	61.90%	56.00%	73.33%	44.44%	65.00%
CNN 1D	76.19%	68.00%	86.67%	55.56%	75.00%
CNN 1D+LSTM	66.67%	48.00%	93.33%	62.96%	80.00%

**Tabel 4.31** Hasil Percobaan Skenario 5 dengan Proses *Undersampling*

Skenario 5 menerapkan proses *Undersampling* untuk *dataset* manual ini. Hasil dapat dilihat pada Tabel 4.31. Dari hasil tersebut, dapat dilihat bahwa akurasi kembali mengalami peningkatan secara signifikan setelah menerapkan proses *Undersampling*. *Traits Openness* yang memiliki akurasi 66.67% mengalami peningkatan sekitar 10% menjadi 76.19% dengan arsitektur CNN 1D. *Traits Conscientiousness* mengalami peningkatan sedikit menjadi 68% juga dengan arsitektur CNN 1D. *Traits Extraversion* dengan proses *Resampling* melewati angka 90% yaitu dengan akurasi tertinggi 93.33% yang didapatkan dengan arsitektur CNN 1D+LSTM dan juga arsitektur MLP. Kedua *traits* lain juga mengalami peningkatan yaitu *Agreeableness* meningkat sekitar 7% menjadi 70.37% dengan MLP dan *Neuroticism* yang meningkat sekitar 3% menjadi 80% dengan CNN 1D+LSTM.

#### 4.2.4.3.3 Skenario 6 (Percobaan dengan menggunakan *Oversampling*)

Arsitektur	O	C	E	A	N
MLP	55.00%	50.00%	64.29%	52.94%	45.45%
LSTM	67.50%	52.94%	59.52%	59.38%	59.09%

GRU	47.50%	<b>61.76%</b>	59.52%	59.38%	56.82%
CNN 1D	60.00%	59.38%	<b>83.33%</b>	<b>61.76%</b>	43.18%
CNN 1D+LSTM	<b>67.50%</b>	<b>61.76%</b>	73.81%	59.38%	56.82%

**Tabel 4.32** Hasil Percobaan Skenario 6 dengan Proses *Oversampling*

Seperti halnya percobaan skenario 3 yang menggunakan proses *Oversampling* pada *dataset myPersonality*, skenario 6 yang juga menerapkan proses *Oversampling* tidak dapat meningkatkan hasil akurasi dengan metode *Deep learning*. Jika dibandingkan dengan skenario 5, tidak ada akurasi tertinggi yang dapat dicapai oleh skenario ini yang melebihi skenario sebelumnya. Rata-rata akurasi tertinggi masih seimbang dengan proses tanpa *Resampling*.

#### 4.2.4.3.4 Kesimpulan Hasil Implementasi *Deep learning* pada *Dataset Manual Gathering*

<i>Traits</i>	<i>Accuracy</i>	<i>Arsitektur</i>	<i>Skenario</i>
<i>Openness</i>	76.19%	CNN 1D	Skenario 5
<i>Conscientiousness</i>	68.00%	CNN 1D	Skenario 5
<i>Extraversion</i>	93.33%	MLP	Skenario 5
		CNN 1D + LSTM	
<i>Agreeableness</i>	70.37%	MLP	Skenario 5
<i>Neuroticism</i>	80.00%	CNN 1D + LSTM	Skenario 5

**Tabel 4.33** Kesimpulan hasil implementasi *Deep learning* pada *Dataset Manual Gathering*

Hasil pada Tabel diatas semakin memperkuat kesimpulan jika penggunaan proses *Undersampling* sangat efektif pada metode *Deep learning* ini. Semua akurasi tertinggi yang di peroleh di percobaan



dengan *dataset* manual ini didapatkan dari skenario 5 yang menerapkan proses *Undersampling*. CNN 1D menjadi arsitektur yang mendominasi karena menjadi arsitektur yang berperan mendapatkan akurasi tertinggi untuk 4 *traits* kepribadian, meskipun digabungkan dengan LSTM untuk *traits Extraversion* dan *Neuroticism*. Arsitektur MLP juga mendapatkan akurasi tertinggi untuk *Extraversion* dan *Neuroticism*.

#### 4.2.4.4 Dataset Gabungan

Percobaan dengan implementasi *Deep learning* skenario 7-9 akan menggunakan *dataset* gabungan.

##### 4.2.4.4.1 Skenario 7 (Percobaan tanpa menggunakan *Resampling*)

Arsitektur	O	C	E	A	N
MLP	62.50%	52.50%	65.00%	57.50%	56.25%
LSTM	58.75%	52.50%	66.25%	48.75%	61.25%
GRU	65.00%	55.00%	61.25%	46.25%	63.75%
CNN 1D	66.25%	58.75%	65.00%	57.50%	52.50%
CNN 1D+LSTM	61.25%	52.50%	62.50%	55.00%	41.25%

**Tabel 4.34** Hasil Percobaan Skenario 7 tanpa Proses *Resampling*

Skenario 7 menggunakan *dataset* gabungan *myPersonality* dan manual dengan tidak menggunakan proses *Resampling*. Hasil akurasi tertinggi yang dapat diperoleh dapat dilihat pada Tabel 4.34 di atas. Akurasi tertinggi didominasi oleh penggunaan arsitektur CNN 1D pada 3 *traits* yaitu *Openness* (66.25%), *Conscientiousness* (58.75%), dan *Agreeableness* (57.50%). Untuk *traits Extraversion* diperoleh dengan arsitektur LSTM dengan akurasi 66.25%. Sedangkan untuk *Neuroticism*, akurasi tertinggi diperoleh dengan arsitektur GRU dengan nilai 63.75%.

#### 4.2.4.4.2 Skenario 8 (Percobaan dengan menggunakan *Undersampling*)

Arsitektur	O	C	E	A	N
MLP	72.00%	54.55%	64.15%	<b>62.16%</b>	67.80%
LSTM	52.00%	40.26%	45.28%	48.65%	49.15%
GRU	52.00%	50.65%	60.38%	59.46%	45.76%
CNN 1D	<b>78.00%</b>	<b>58.44%</b>	<b>79.25%</b>	52.70%	<b>74.58%</b>
CNN 1D+LSTM	72.00%	51.95%	77.36%	51.35%	71.19%

**Tabel 4.35** Hasil Percobaan Skenario 8 dengan Proses *Undersampling*

Penggunaan proses *Undersampling* pada *dataset* gabungan ini juga meningkatkan hasil akurasi. Hasil dapat dilihat pada Tabel 4.35, dimana hasil akurasi tertinggi *Openness* yang semula hanya 66.25% pada skenario 7 menjadi 78% setelah penggunaan proses *Undersampling*. Arsitektur CNN 1D mendominasi dengan mendapatkan akurasi tertinggi untuk 4 *traits* yaitu, *Openness* (78.00%), *Conscientiousness* (58.44%), *Extraversion* (79.25%), dan *Neuroticism* (74.58%). Sedangkan untuk *Agreeableness* diperoleh dengan arsitektur MLP dengan akurasi 62.16%. Penggunaan proses *Undersampling* telah terbukti meningkatkan akurasi pada metode *Deep learning* dengan hasil yang ditunjukkan oleh skenario 2, 5, dan 8 yang menerapkan proses *Undersampling* pada *dataset*.

#### 4.2.4.4.3 Skenario 9 (Percobaan dengan menggunakan *Oversampling*)

Arsitektur	O	C	E	A	N
MLP	46.15%	45.56%	<b>63.21%</b>	45.12%	52.04%
LSTM	48.08%	44.57%	51.92%	48.75%	50.96%
GRU	52.88%	<b>57.61%</b>	50.96%	51.25%	49.04%

CNN 1D	49.04%	48.89%	61.32%	<b>53.66%</b>	<b>58.16%</b>
CNN 1D+LSTM	<b>54.81%</b>	54.35%	48.08%	47.50%	56.73%

**Tabel 4.36** Hasil Percobaan Skenario 9 dengan Proses *Oversampling*

Berbanding terbalik dengan proses *Undersampling*, Hal yang sama kembali ditunjukkan oleh penerapan proses *Oversampling* yang tidak membantu meningkatkan akurasi pada percobaan skenario 9 ini. Bahkan tidak ada akurasi tertinggi yang melebihi akurasi tertinggi pada skenario 7 yang tidak menggunakan proses *Resampling*. Rata-rata akurasi yang dicapai juga memiliki nilai dibawah 50%, semakin menurun dibandingkan dengan rata-rata akurasi pada skenario 7 yang berada diatas 50%. Dengan hasil percobaan akhir ini, proses *Oversampling* juga semakin terbukti tidak dapat membantu meningkatkan hasil akurasi meskipun diterapkan di berbagai *dataset* berbeda seperti terlihat pada skenario 3, 6, dan 9.

#### 4.2.4.4.4 Kesimpulan Hasil Implementasi *Deep learning* pada *Dataset Gabungan*

<i>Traits</i>	Accuracy	Algorithm	Skenario
<i>Openness</i>	78.00%	CNN 1D	Skenario 8
<i>Conscientiousness</i>	58.75%	CNN 1D	Skenario 7
<i>Extraversion</i>	79.25%	CNN 1D	Skenario 8
<i>Agreeableness</i>	62.16%	MLP	Skenario 8
<i>Neuroticism</i>	74.58%	CNN 1D	Skenario 8

**Tabel 4.37** Kesimpulan hasil implementasi *Deep learning* pada *Dataset Gabungan*

Implementasi *Deep learning* pada *dataset* gabungan ini berhasil mendapatkan akurasi tertinggi dengan menerapkan proses *Undersampling* seperti yang terjadi pada percobaan dengan *dataset* sebelumnya. *Traits Openness*, *Extraversion*, *Agreeableness*, dan *Neuroticism* mendapatkan akurasi tertinggi dengan menggunakan proses *Undersampling*. Arsitektur yang paling dominan adalah CNN 1D yang mendapatkan akurasi tertinggi di semua *traits* kecuali *Agreeableness*. Akurasi tertinggi yang berhasil didapatkan adalah 79.25% untuk *traits Extraversion* dengan arsitektur CNN 1D dan penggunaan proses *Resampling*. Hasil kesimpulan dari implementasi *Deep learning* pada *dataset* gabungan ini dapat dilihat pada Tabel 4.37.

#### 4.2.4.5 Kesimpulan Implementasi *Deep learning*

**Tabel 4.38** Kesimpulan Hasil Implementasi *Deep learning*

<i>Traits</i>	<i>Accuracy</i>	<i>Arsitektur</i>	<i>Proses</i>
<i>Openness</i>	78.00%	CNN 1D	<i>Undersampling</i>
<i>Conscientiousness</i>	68.00%	CNN 1D	<i>Undersampling</i>
<i>Extraversion</i>	93.33%	CNN 1D + LSTM	<i>Undersampling</i>
		MLP	
<i>Agreeableness</i>	70.37%	MLP	<i>Undersampling</i>
<i>Neuroticism</i>	80.00%	CNN 1D + LSTM	<i>Undersampling</i>

Setelah melakukan implementasi metode *Deep learning* pada tiga *dataset* berbeda dengan 3 skenario di masing-masing *dataset* tersebut. Peneliti membuat sebuah kesimpulan yang diperoleh dari seluruh percobaan tersebut. Hasil akurasi tertinggi dari setiap skenario dibandingkan dan dipilih yang memiliki nilai tertinggi. Tabel hasil kesimpulan akurasi tertinggi di implementasi *Deep learning* dapat dilihat pada Tabel 4.38 di atas.

Dari hasil diatas, penggunaan proses *Undersampling* terbukti dapat meningkatkan hasil akurasi di metode *Deep learning*. Penerapan proses *Undersampling* berhasil mencatatkan akurasi tertinggi di seluruh *traits* dalam percobaan di seluruh skenario dengan *dataset* yang berbeda. *Traits Extraversion* memiliki akurasi tertinggi yaitu 93.33% dengan menggunakan MLP atau CNN 1D+LSTM. *Traits Neuroticism* memiliki akurasi tertinggi kedua dengan 80.00% menggunakan CNN 1D+LSTM. Kemudian *traits Openness* dengan menggunakan CNN 1D berhasil mendapatkan akurasi tertinggi 78.00%. *Traits Agreeableness* dengan akurasi tertinggi 70.37% menggunakan arsitektur MLP. *Traits Neuroticism* memiliki akurasi terendah dalam tabel kesimpulan ini dengan nilai 68.00% menggunakan CNN 1D.

Setelah hasil kedua implementasi yaitu implementasi *Machine learning* dan implementasi *Deep learning* didapatkan, maka peneliti mengambil keputusan untuk menggunakan implementasi *Deep learning* untuk sistem prediksi kepribadian pada penelitian ini karena memiliki akurasi yang lebih tinggi untuk semua *traits* dibandingkan dengan implementasi *Machine learning*.

Maka untuk aplikasi sistem prediksi kepribadian pada penelitian ini akan menerapkan arsitektur dan proses seperti terlihat pada Tabel 4.38.

#### 4.2.5 Tampilan Layar Aplikasi

Hasil akhir aplikasi sistem prediksi kepribadian ini akan berupa sebuah aplikasi web. Gambar 4.1 hingga 4.5 adalah tampilan layar aplikasi.



**Gambar 4.1** Tampilan halaman utama aplikasi

Tampilan layar utama aplikasi memuat sebuah tombol “*Log In with Facebook*” di bagian tengah layar yang akan meminta *user* untuk *login* ke dalam akun Facebook mereka. Di bagian pojok kiri bawah layar terdapat tombol “*Privacy Policy*” yang akan memindahkan *user* ke halaman *Privacy Policy* yang dapat dilihat pada Gambar 4.8 dan 4.9.

Setelah *user* masuk ke dalam akun Facebook mereka, halaman akan berpindah ke bagian *Result* yang dapat dilihat pada Gambar 4.2 hingga 4.7. Halaman *Result* berisi hasil kepribadian dari *user* tersebut. Seperti terlihat pada Gambar 4.2, dimana terdapat 5 *traits* kepribadian *Big Five Personality* di bagian kanan halaman. Masing-masing *traits* tersebut akan memiliki *bar chart* yang terhubung di sisi kirinya. Setiap *bar chart* dalam keadaan tertutup. Untuk membuka *bar chart* tersebut, *user* harus melakukan *hover* ke *bar chart* tersebut atau *hover* ke masing-masing *traits*. Gambar 4.2 di bawah ini memperlihatkan keadaan dimana *user* sedang melakukan *hover* ke bagian *Openness*.



**Gambar 4.2** Tampilan halaman hasil dengan *Openness bar chart* terbuka



**Gambar 4.3** Tampilan halaman hasil dengan *Conscientiousness bar chart* terbuka

Gambar 4.3 diatas memperlihatkan keadaan ketika *user* melakukan hover di *traits Conscientiousness*.



**Gambar 4.4** Tampilan halaman hasil dengan *Extraversion bar chart* terbuka


Gambar 4.4 diatas memperlihatkan keadaan ketika *user* melakukan *hover* di *traits Extraversion*.



**Gambar 4.5** Tampilan halaman hasil dengan *Agreeableness bar chart* terbuka

Gambar 4.5 diatas memperlihatkan keadaan ketika *user* melakukan *hover* di *traits Agreeableness*.



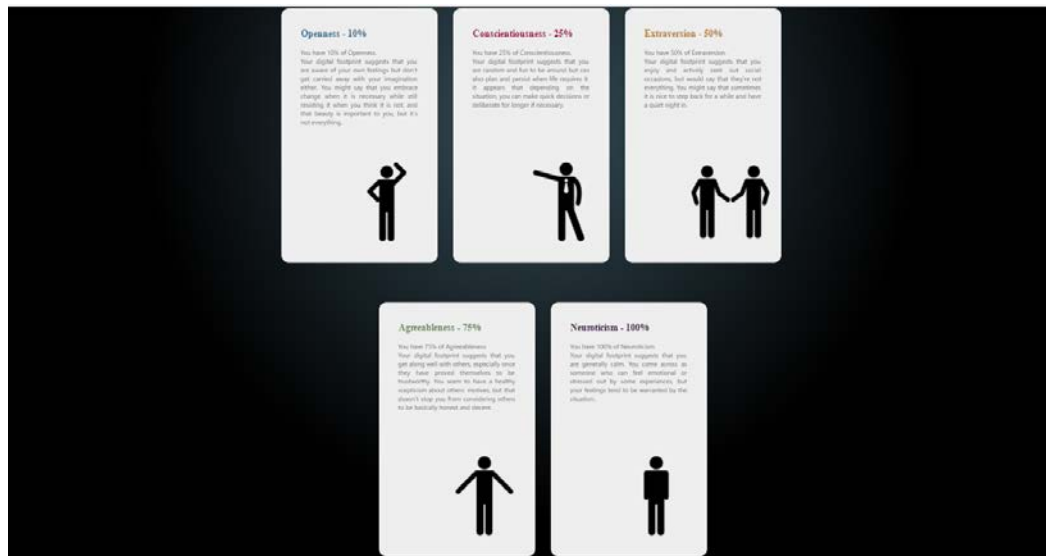


**Gambar 4.6** Tampilan halaman hasil dengan *Neuroticism bar chart* terbuka

Gambar 4.6 diatas memperlihatkan keadaan ketika *user* melakukan *hover* di *traits Neuroticism*.



**Gambar 4.7** Tampilan semua hasil *traits* secara keseluruhan



**Gambar 4.8** Tampilan halaman hasil bagian penjelasan hasil masing-masing *traits*

Gambar 4.7 memperlihatkan semua hasil *traits* secara keseluruhan beserta tingkat kepribadiannya, jika hasil *traits* di bawah 50% maka *traits* dikategorikan “Low”, jika hasil *traits* di atas 50% maka *traits* dikategorikan “High”. Gambar 4.8 memperlihatkan hasil halaman *Result* setelah di *scroll* ke bawah dan berada tepat di bawah *bar chart* masing-masing *traits* sebelumnya. Tampilan di atas adalah penjelasan lebih jelas mengenai masing-masing *traits* yang diperoleh oleh *user*. Setiap *traits* akan berada dalam sebuah kotak yang berisi judul berupa *traits* contohnya *Openness* dan diikuti persentase kepribadiannya. Di bawah judul terdapat penjelasan lengkap mengenai *traits user* tersebut.

#### Privacy Policy

This privacy policy has been compiled to better serve those who are concerned with how their Personally Identifiable Information (PII) is being used online. PII, as described in US privacy law and information security, is information that can be used on its own or with other information to identify, contact, or locate a single person, or to identify an individual in context. Please read our privacy policy carefully to get a clear understanding of how we collect, use, protect or otherwise handle your Personally Identifiable Information in accordance with our website.

##### What personal information do we collect from the people that visit our blog, website or app?

When ordering or registering on our site, as appropriate, you may be asked to enter your name, Facebook User ID, Facebook Posts or other details to help you with your experience.

##### When do we collect information?

We collect information from you when you or enter information on our site.

Log In with Facebook

##### How do we use your information?

We may use the information we collect from you when you register, make a purchase, sign up for our newsletter, respond to a survey or marketing communication, surf the website, or use certain other site features in the following ways:

- To improve our website in order to better serve you.

##### How do we protect your information?

We do not use vulnerability scanning and/or scanning to PCI standards.  
We only provide articles and information. We never ask for credit card numbers.  
We do not use Malware Scanning.

We do not use an SSL certificate

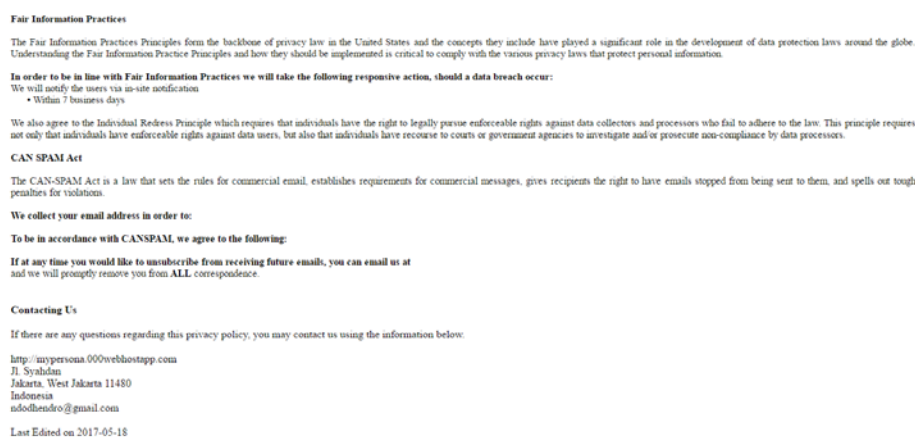
- We do not use an SSL certificate.
- We will add SSL certificate to the website as soon as possible.

##### Do we use 'cookies'?

Yes. Cookies are small files that a site or its service provider transfers to your computer's hard drive through your Web browser (if you allow) that enables the site's or service provider's systems to recognize your browser and capture and remember certain information. For instance, we use cookies to help us remember and process the items in your shopping cart. They are also used to help us understand your preferences based on previous or current site activity, which enables us to provide you with improved services. We also use cookies to help us compile aggregate data about site traffic and site interaction so that we can offer better site experiences and tools in the future.

**Gambar 4.9** Tampilan halaman *privacy policy*

Gambar 4.9 adalah tampilan halaman *privacy policy* yang dapat dibuka dengan mengklik tombol “*Privacy Policy*” yang ada pada halaman utama. Halaman ini berisi penjelasan mengenai data apa saja yang didapatkan dari *user*, cara mendapatkan data dari *user*, apa tujuan peneliti menggunakan data tersebut, bagaimana peneliti menjaga keamanan data tersebut dan sebagainya. Di bagian paling bawah dari halaman ini juga terdapat informasi kontak dari peneliti yang dapat di lihat pada Gambar 4.10.




**Gambar 4.10** Tampilan halaman lanjutan *privacy policy*

## 4.3 Evaluasi


### 4.3.1 Evaluasi Subjektif

Evaluasi Subjektif dilakukan dengan melakukan wawancara terhadap beberapa responden yang diminta untuk mencoba dan mengevaluasi sistem prediksi kepribadian dari penelitian ini. Responden yang mengikuti wawancara merupakan pengguna aktif sosial media Facebook dan memiliki status di *feed* akun mereka.

Responden akan diberikan beberapa pertanyaan secara langsung melalui tanya jawab oleh peneliti, kemudian responden akan diminta untuk memberikan nilai kepuasan terhadap penggunaan sistem prediksi kepribadian yang telah dibuat serta saran atau masukan oleh para Responden terhadap aplikasi. Berikut adalah informasi demografis para Responden:



**Gambar 4.11** *Pie chart* Distribusi Jenis Kelamin Responden



**Gambar 4.12** *Pie chart* Distribusi Umur Responden

Gambar 4.11 menampilkan distribusi jenis kelamin dari responden penelitian. Sedangkan Gambar 4.12 menampilkan distribusi umur dari responden. Berikut adalah poin-poin penting yang didapatkan melalui hasil wawancara terhadap para Responden.

1. 8 dari 10 responden menggunakan sosial media Facebook setiap hari. Sedangkan 2 lainnya menggunakan Facebook beberapa hari sekali.
2. Para responden berpendapat bahwa tampilan layar aplikasi sudah cukup bagus dengan nilai rata-rata 8.6 dari 10.
3. Para responden berpendapat sistem prediksi yang dikembangkan menghasilkan akurasi dalam waktu yang cepat.
4. Para responden berpendapat hasil prediksi untuk *traits Openness* lumayan akurat dengan nilai rata-rata 7.6 dari 10.

5. Para responden berpendapat hasil prediksi untuk *traits Conscientiousness* cukup akurat dengan nilai rata-rata 7.2 dari 10.
6. Para responden berpendapat hasil prediksi untuk *traits Extraversion* cukup akurat dengan nilai rata-rata 6.6 dari 10.
7. Para responden berpendapat hasil prediksi untuk *traits Agreeableness* lumayan akurat dengan nilai rata-rata 7.5 dari 10.
8. Para responden berpendapat hasil prediksi untuk *traits Neuroticism* cukup akurat dengan nilai rata-rata 6.9 dari 10.
9. 8 dari 10 responden berpendapat bahwa sistem prediksi kepribadian akan bermanfaat dalam kehidupan mereka.
10. Para responden berpendapat bahwa keseluruhan sistem aplikasi sistem prediksi kepribadian ini sudah cukup baik, beberapa responden memberikan saran untuk meningkatkan hasil akurasi prediksi kepribadian, karena masih ada beberapa prediksi yang dianggap kurang tepat. Selain itu, terdapat juga saran dari responden untuk membuat versi *mobile* agar lebih mudah digunakan.

**Tabel 4.39** Penilaian Kuantitatif untuk setiap *Traits* oleh Responden Penelitian

<b>Responden</b>	<b><i>Openness</i></b>	<b><i>Conscientiousness</i></b>	<b><i>Extraversion</i></b>	<b><i>Agreeableness</i></b>	<b><i>Neuroticism</i></b>
<b>1</b>	10	7	1	8	5
<b>2</b>	8	8	1	8	8
<b>3</b>	6	8	7	6	7
<b>4</b>	7	9	9	9	5
<b>5</b>	9	8	6	10	7
<b>6</b>	8	6	5	9	7
<b>7</b>	4	8	10	3	8
<b>8</b>	9	3	8	9	8
<b>9</b>	7	7	9	10	6
<b>10</b>	8	8	10	3	8
<b>Rata-rata</b>	<b>7.6</b>	<b>7.2</b>	<b>6.6</b>	<b>7.5</b>	<b>6.9</b>

### 4.3.2 Evaluasi Objektif

Evaluasi Objektif dilakukan dengan membandingkan hasil yang diperoleh oleh penelitian ini dengan penelitian sebelumnya yang menggunakan model kepribadian *Big Five Traits* dan mencantumkan hasil akurasi penelitian, karena aspek utama yang menjadi perbandingan adalah hasil akurasi dari sistem prediksi kepribadian untuk setiap *traits* dari *Big Five Model Personality*.

#### 4.3.2.1 Sistem Prediksi Kepribadian “The Big Five Traits” Dari Data Twitter

Penelitian yang bertujuan untuk membangun sebuah sistem prediksi kepribadian ini dilakukan oleh Wijaya, Prasetia, Febrianto, dan Suhartono. Walaupun penelitian menggunakan *dataset* dari sosial media Twitter, evaluasi dilakukan karena metode, fitur dan algoritma yang digunakan memiliki beberapa kesamaan dan pantas untuk dilakukan perbandingan hasil akurasi. Selain itu, penelitian yang dilakukan oleh Wijaya, Prasetia, Febrianto, dan Suhartono ini juga menggunakan bahasa Inggris. Algoritma yang digunakan pada penelitian adalah Support Vector Machine, Naïve Bayes, dan ZeroR. Fitur Linguistik yang digunakan yaitu gabungan dari fitur LIWC dan MRC.

**Tabel 4.40** Perbedaan antara penelitian Sistem Prediksi Kepribadian “The Big Five Traits” Dari Data Twitter dan Penelitian Ini

Perbedaan	Sistem Prediksi Kepribadian “The Big Five Traits” Dari Data Twitter	Penelitian Ini
Five Factor Model	✓	✓
<i>Machine learning</i>		
Support Vector Machine	✓	✓
ZeroR	✓	
Naïve Bayes	✓	✓
Linear Discriminant Analysis		✓

Gradient Boosting		✓
Logistic Regression		✓
<i>Deep learning</i>		✓
<i>Features</i>		
LIWC	✓	✓
MRC	✓	
SPLICE		✓
Open Vocabulary		✓

Evaluasi objektif dilakukan dengan membandingkan akurasi tertinggi dari setiap *traits* kepribadian antara kedua penelitian diatas. Penelitian yang dilakukan oleh Wijaya, Prasetya, Febrianto, dan Suhartono hanya menampilkan hasil akurasi dengan algoritma SVM karena algoritma tersebut merupakan fokus dari penelitian dan digunakan pada sistem prediksi. Perbandingan akurasi kedua penelitian dapat dilihat pada Tabel 4.41.

Hasil perbandingan antara metode *Machine learning* kedua penelitian cukup seimbang. Penelitian ini hanya berhasil mengungguli hasil akurasi penelitian sebelumnya pada *traits Openness, Extraversion*. Sedangkan untuk *traits Conscientiousness, Agreeableness, dan Neuroticism*, masih belum dapat mengungguli akurasi dari penelitian sebelumnya. Namun, penggunaan implementasi *Deep learning* penelitian ini memiliki hasil yang lebih baik dan unggul di 3 *traits* kepribadian yaitu, *Openness, Extraversion, dan Agreeableness*.

Hasil akurasi yang berbeda kemungkinan besar disebabkan karena *dataset* yang digunakan berbeda dalam jumlah maupun jenis. *Dataset* yang digunakan pada penelitian sebelumnya sebanyak kurang lebih 5 ribu data, sedangkan penelitian ini hanya menggunakan sekitar 400 *dataset*. Penggunaan metode *Deep learning* memberikan hasil yang cukup baik meski dengan *dataset* yang lebih sedikit dan mungkin dapat ditingkatkan lagi jika diimplementasikan dengan *dataset* yang lebih besar.

**Tabel 4.41** Tabel perbandingan akurasi penelitian Sistem Prediksi Kepribadian “The Big Five Traits” Dari Data Twitter dan Penelitian Ini

<i>Traits</i>	Sistem Prediksi Kepribadian “The Big Five Traits” Dari Data Twitter	Penelitian Ini	
	<i>Machine Learning</i>	<i>Machine Learning</i>	<i>Deep Learning</i>
<i>Openness</i>	61.436 (SVM)	70.4 (Logistic Regression)	78 (CNN 1D)
<i>Conscientiousness</i>	80.876 (SVM)	67.33 (LDA)	68 (CNN 1D)
<i>Extraversion</i>	64.3938 (SVM)	79.33 (LDA)	93.33 (CNN 1D + LSTM)
<i>Agreeableness</i>	77.8957 (SVM)	63.2 (Gradient Boosting)	70.37 (MLP)
<i>Neuroticism</i>	70.5351 (SVM)	70 (Naïve Bayes)	80 (CNN 1D + LSTM)

#### 4.3.2.2 *Personality Traits Recognition on Social Network – Facebook*

Penelitian sebelumnya yang menggunakan sosial media Facebook sebagai *dataset* dilakukan oleh Alam, Stepanov, dan Riccardi. Penelitian ini menggunakan *dataset* yang sama persis dengan penelitian kali ini yaitu *dataset myPersonality* (Kosinski, 2015) sebanyak 250 data *user* dan kurang lebih 10.000 status. Algoritma yang digunakan pada penelitian oleh Alam, Stepanov, dan Riccardi adalah SVM, Logistic Regression, dan Naïve Bayes. Feature Extraction dan klasifikasi pada penelitian sebelumnya menggunakan WEKA (Witten, 2011).



**Tabel 4.42** Perbedaan antara penelitian *Personality Traits Recognition on Social Network – Facebook* dan Penelitian Ini

Perbedaan	<i>Personality Traits Recognition on Social Network – Facebook</i>	Penelitian Ini
Five Factor Model	✓	✓
<i>Machine learning</i>		
Support Vector Machine	✓	✓
Naïve Bayes	✓	✓
Logistic Regression	✓	✓
Linear Discriminant Analysis		✓
Gradient Boosting		✓
<i>Deep learning</i>		✓
<i>Features</i>		
LIWC		✓
SPLICE		✓
Open Vocabulary	✓	✓

Evaluasi objektif dilakukan dengan membandingkan akurasi tertinggi dari setiap *traits* kepribadian antara penelitian yang dilakukan oleh Alam, Stepanov, dan Riccardi dengan penelitian ini. Perbedaan antara kedua penelitian terdapat pada fitur yang dipakai pada implementasi *Machine learning* dimana penelitian sebelumnya mengimplementasikan open-vocabulary sebagai fitur, sedangkan penelitian ini menggunakan closed-vocabulary. Walaupun demikian, implementasi *Deep learning* yang digunakan pada penelitian ini juga menggunakan open-vocabulary sebagai fitur utama. Untuk itu hasil akurasi dengan menggunakan implementasi *Deep learning* juga akan diikutsertakan dalam tabel perbandingan hasil akurasi. Hasil perbandingan akurasi kedua penelitian dapat dilihat pada Tabel 4.43 di bawah ini.

**Tabel 4.43** Tabel perbandingan akurasi penelitian *Personality Traits Recognition on Social Network – Facebook* dan Penelitian Ini

<i>Traits</i>	<i>Personality Traits Recognition on Social Network – Facebook</i>	<b>Penelitian Ini</b>	
	<i>Machine Learning</i>	<i>Machine Learning</i>	<i>Deep Learning</i>
<i>Openness</i>	69.48 (Naïve Bayes)	70.4 (Logistic Regression)	78 (CNN 1D)
<i>Conscientiousness</i>	59.4 (Naïve Bayes)	67.33 (LDA)	68 (CNN 1D)
<i>Extraversion</i>	58.6 (Naïve Bayes)	79.33 (LDA)	93.33 (CNN 1D + LSTM)
<i>Agreeableness</i>	59.16 (Naïve Bayes)	63.2 (Gradient Boosting)	70.37 (MLP)
<i>Neuroticism</i>	63.0 (Naïve Bayes)	70 (Naïve Bayes)	80 (CNN 1D + LSTM)

Dari Tabel 4.43 dapat dilihat bahwa implementasi *Machine learning* yang digunakan pada penelitian ini mengungguli hasil akurasi dari semua *traits* pada penelitian sebelumnya. Fitur yang digunakan merupakan salah satu alasan penting yang menyebabkan perbedaan hasil kedua penelitian. Namun, terdapat 3 *traits* dimana penelitian ini mengungguli penelitian sebelumnya, menggunakan algoritma yang tidak digunakan pada penelitian sebelumnya yaitu Linear Discriminant Analysis (LDA) dan Gradient Boosting. Hal itu dapat menjadi faktor keunggulan penelitian ini.

Jika dibandingkan dengan penggunaan fitur yang sama yaitu open-vocabulary. Penelitian ini yang menggunakan *Deep learning* jauh mengungguli hasil penelitian sebelumnya di semua *traits* kepribadian. Hal ini menghasilkan kesimpulan bahwa open-vocabulary dapat digunakan lebih efektif pada metode *Deep learning*. Semakin luas dan besar fitur dari *dataset* yang dimiliki, semakin efektif metode *Deep learning* bekerja.

#### 4.3.2.3 *Deep Learning-Based Document Modeling for Personality Detection from Text*

Salah satu penelitian yang menerapkan implementasi *Deep Learning* dilakukan oleh Majumder, Poria, Gelbukh, & Cambria. Jenis kepribadian yang digunakan adalah *Big Five Personality Traits* yang sama dengan penelitian ini. Metode yang digunakan oleh penelitian Majumder et al. meliputi *preprocessing* data input dan *filtering*, *Feature Extraction*, dan *Classification*. Untuk *Word-Level Feature Extraction*, penelitian oleh Majumder et al. menggunakan *word2vec embeddings* dan klasifikasi menggunakan arsitektur CNN dan classifier MLP serta SVM. *Dataset* yang digunakan dalam penelitian sebelumnya terdiri dari 2.468 esai tanpa nama yang telah diberi label kepribadian dari penulis, Untuk melakukan evaluasi terhadap hasil *training*. Penelitian sebelumnya menggunakan *10-fold cross-validation*. Perbandingan jelas antara perbedaan metodologi antara penelitian sebelumnya dengan penelitian ini dapat dilihat pada Tabel 4.44.

**Tabel 4.44** Perbedaan antara penelitian *Deep Learning-Based Document Modeling for Personality Prediction from Text* dan Penelitian Ini

Perbedaan	<i>Personality Traits Recognition on Social Network – Facebook</i>	Penelitian Ini
Five Factor Model	✓	✓
<i>Machine learning</i>		
SVM	✓	✓
Naïve Bayes		✓
Logistic Regression		✓
<i>Deep learning</i>		
CNN	✓	✓
Mairesse	✓	
MLP		✓
LSTM		✓
GRU		✓
<i>Features</i>		

LIWC		✓
SPLICE		✓
Open Vocabulary	✓	✓

Evaluasi objektif dilakukan dengan membandingkan akurasi tertinggi dari setiap *traits* kepribadian antara penelitian yang dilakukan oleh Majumder, Poria, Gelbukh, & Cambria dengan penelitian ini. Kedua penelitian sama-sama menggunakan implementasi *Deep Learning* dan arsitektur yang sama yaitu CNN. Perbedaan terdapat pada jenis *dataset* yang digunakan dimana penelitian sebelumnya menggunakan *dataset* esai sebanyak 2,468 esai, sedangkan penelitian ini menggunakan *dataset* status pengguna sosial media Facebook yang berjumlah sekitar 400 user. Hasil perbandingan akurasi kedua penelitian dapat dilihat pada Tabel 4.45 di bawah ini.

**Tabel 4.45** Tabel perbandingan akurasi penelitian *Deep Learning-Based Document Modeling for Personality Prediction from Text* dan Penelitian Ini

<i>Traits</i>	<i>Deep Learning-Based Document Modeling for Personality Detetction from Text</i>	Penelitian Ini
	<i>Deep Learning</i>	<i>Deep Learning</i>
<i>Openness</i>	62.68 (CNN + Mairesse)	78 (CNN 1D)
<i>Conscientiousness</i>	57.30 (CNN + Mairesse)	68 (CNN 1D)
<i>Extraversion</i>	58.09 (CNN + Mairesse)	93.33 (CNN 1D + LSTM)
<i>Agreeableness</i>	56.71 (CNN + Mairesse)	70.37 (MLP)
<i>Neuroticism</i>	59.38 (CNN + Mairesse)	80 (CNN 1D + LSTM)

Dari tabel perbandingan akurasi di atas dapat dilihat bahwa penelitian ini yang mengimplementasikan *Deep Learning* untuk sistem prediksi kepribadian berhasil mengungguli penelitian sebelumnya di semua *traits* kepribadian. Penelitian sebelumnya memiliki akurasi tertinggi yaitu 62.68% untuk *traits Openness*, sedangkan penelitian ini berhasil unggul sekitar 16% untuk *traits* yang sama. Arsitektur kedua penelitian ini juga di dominasi oleh arsitektur CNN dan gabungan dengan LSTM. Perbedaan akurasi kemungkinan besar disebabkan oleh *dataset* yang berbeda.